FATEC VOTORANTIM
CIÊNCIA DE DADOS PARA NEGÓCIOS

DÉBORA KOCKS NOGUEIRA
GIOVANA PERUGINI GUENKA
STEFANIE MAYUMI INACIO KOBAYASHI
VITÓRIA LISAUSKAZ FERRAZ DA SILVA

DEPLOY GUIDE — MODELO PREDITIVO DE HOTSPOTS

Predição de Risco de Violência Contra a Mulher — DDMs Sorocaba/Votorantim

Votorantim — SP
2026

Sumário

1. Objetivo 5
2. Escopo 5
3. Definições e Siglas 5
4. Visão Geral da Solução 6
    4.1 Descrição do Modelo 6
    4.2 Tipo de Modelo 6
    4.3 Features de Entrada 6
    4.4 Fluxo da Solução 7
5. Arquitetura da Solução 7
6. Estrutura do Projeto 8
7. Pré-requisitos 9
    7.1 Requisitos de Hardware (Servidor Doméstico) 9
    7.2 Requisitos de Software 9
    7.3 Acesso ao Subdomínio 9
8. Configuração do Ambiente 9
    8.1 Clonar ou copiar o projeto 9
    8.2 Criar o ambiente virtual Python 9
    8.3 Ativar o ambiente virtual 9
    8.4 Instalar as dependências 10
    8.5 Verificar os artefatos do modelo 10
9. Execução Local (Desenvolvimento e Testes) 10
10. Deploy no Servidor Doméstico 10
    10.1 Execução em segundo plano com systemd (Linux) 10
    10.2 Configuração de Port Forward no Roteador 11
    10.3 Endereço de acesso 11
11. Variáveis de Ambiente 11
12. Segurança 12
13. Monitoramento 12
14. Atualização do Modelo 12
    14.1 Quando re-treinar 12
    14.2 Processo de atualização 13
    14.3 Versionamento de modelos 13
15. Testes 13
    15.1 Teste de smoke (fumaça) — verificação básica 13
    15.2 Teste de predição de referência 13
    15.3 Teste de robustez 13
16. Desempenho do Modelo em Produção 14
17. Riscos e Mitigações 14
18. Responsáveis 15
19. Aprovação 15

Controle de Versão

Versão	Data	Autor	Descrição
1.0	Mai/2026	Stefanie Kobayashi	Criação inicial do documento

1. Objetivo

Este documento descreve o processo completo de implantação (deploy) do modelo preditivo de hotspots de Violência Contra a Mulher (VCM), desenvolvido no âmbito do Projeto Integrador 5 (PI5) da Fatec Votorantim, curso de Ciência de Dados para Negócios.

O sistema tem como objetivo apoiar a análise preventiva de risco de ocorrências de agressão contra a mulher nos municípios de Sorocaba e Votorantim, com base em dados históricos das Delegacias de Defesa da Mulher (DDMs) disponibilizados pela Secretaria de Segurança Pública do Estado de São Paulo (SSP-SP).

O deploy está disponível em ambiente acadêmico no endereço:

https://pifatec.useconectai.com.br

2. Escopo

Este documento cobre os seguintes aspectos do ciclo de vida do modelo em produção:

- Configuração do ambiente Python e instalação de dependências
- Execução local do aplicativo Streamlit para desenvolvimento e testes
- Deploy em servidor doméstico (on-premises) com acesso via subdomínio público
- Monitoramento básico de disponibilidade e desempenho
- Estratégia de atualização e re-treinamento do modelo

Não estão no escopo deste documento: coleta e tratamento dos dados brutos (cobertos no notebook 01_etl.ipynb), processo de treinamento do modelo (coberto no notebook 03_modelagem_preditiva.ipynb) e integrações com sistemas externos de segurança pública.

3. Definições e Siglas

Termo / Sigla	Descrição
DDM	Delegacia de Defesa da Mulher
ML	Machine Learning (Aprendizado de Máquina)

Termo / Sigla	Descrição
XGBoost	Extreme Gradient Boosting — algoritmo de ensemble utilizado no modelo
Streamlit	Framework Python para criação de aplicações web de dados
Target Encoding	Técnica de codificação de variáveis categóricas pela média do target
Hotspot	Área geográfica com concentração elevada de ocorrências criminais
VCM	Violência Contra a Mulher
SSP-SP	Secretaria de Segurança Pública do Estado de São Paulo
PI5	Projeto Integrador 5 — disciplina da Fatec Votorantim
ROC-AUC	Área sob a curva ROC — métrica de desempenho do modelo
pkl	Formato de serialização de objetos Python (Pickle)
JSON	JavaScript Object Notation — formato de troca de dados
venv	Ambiente virtual Python para isolamento de dependências
Deploy	Processo de disponibilização de um sistema em ambiente de produção

4. Visão Geral da Solução

4.1 Descrição do Modelo

O modelo preditivo foi desenvolvido para classificar combinações de bairro × mês × ano como hotspot (alto risco de ocorrência de agressão) ou risco normal, com base em padrões históricos extraídos das ocorrências registradas nas DDMs de Sorocaba e Votorantim entre 2022 e 2026.

4.2 Tipo de Modelo

Tipo: Classificação Binária (ocorreu = 1 / não ocorreu = 0)

Algoritmo: XGBoost (Extreme Gradient Boosting) com RandomizedSearchCV para otimização de hiperparâmetros

Balanceamento: Random UnderSampler com razão 1:3 (positivos:negativos)

Validação: Validação cruzada estratificada com 5 folds (StratifiedKFold)

4.3 Features de Entrada

Feature	Tipo	Descrição
mes_ocorrencia	Numérica (1–12)	Mês do cenário a ser previsto — captura sazonalidade
bairro_target_enc	Numérica (0–1)	Score de risco histórico do bairro (Target Encoding)
lag_mensal	Numérica	Quantidade de ocorrências no mês imediatamente anterior
lag_anual	Numérica	Quantidade de ocorrências no mesmo mês do ano anterior
media_movel_3m	Numérica	Média de ocorrências nos últimos 3 meses no bairro
municipio_enc	Categórica codificada	Município codificado (0 = Sorocaba, 1 = Votorantim ou vice-versa)
ano_ocorrencia	Numérica	Ano do cenário — captura tendências temporais

4.4 Fluxo da Solução

- Usuário seleciona município, bairro, mês e ano na interface web
- O aplicativo Streamlit recupera o score de risco do bairro (Target Encoding) e os lags históricos dos arquivos JSON
- O vetor de features é montado e passado ao modelo XGBoost (.pkl)
- O modelo retorna a probabilidade de hotspot (0 a 1)
- O resultado é exibido em 4 níveis: Baixo (< 25%), Atenção (25–50%), Alto (50–75%), Crítico (> 75%)

5. Arquitetura da Solução

O sistema adota arquitetura monolítica simples, adequada ao escopo acadêmico e ao volume de uso esperado. Não há banco de dados em tempo real, todas as informações necessárias para predição são pré-calculadas e armazenadas em arquivos locais (JSON/pkl) gerados pelo notebook de treinamento.

Camada	Tecnologia	Responsabilidade
Frontend / Interface	Streamlit (Python)	Formulário de entrada, exibição do resultado e nível de risco
Lógica de Predição	XGBoost + scikit-learn	Cálculo da probabilidade de hotspot a partir das features
Artefatos do Modelo	Arquivos .pkl e .json	Encoders, score por bairro, lags históricos

Camada	Tecnologia	Responsabilidade
Servidor Web	Servidor doméstico (on-premises)	Hospedagem do app Streamlit com acesso externo
Roteamento de DNS	Subdomínio pifatec.useconectai.com.br	Redirecionamento de domínio para o IP do servidor

6. Estrutura do Projeto

```
ProjetoIntegrador5/
│
├── app.py                    # Aplicativo Streamlit principal
├── requirements.txt          # Dependências Python
├── credenciais.json          # Credenciais BigQuery (não versionar)
│
├── models/                   # Artefatos exportados pelo notebook 03
│   ├── modelo_hotspot_xgboost_v1.pkl
│   ├── encoder_municipio.pkl
│   ├── target_encoding_bairros.json
│   ├── stats_bairros.json
│   └── bairro_municipio_map.json
│
├── notebooks/
│   ├── 01_etl.ipynb          # Pipeline de extração e carga
│   └── 03_modelagem_preditiva.ipynb  # Treinamento e exportação
│
└── docs/                     # Gráficos e documentação
```

Descrição dos arquivos do sistema:

Arquivo	Local	Descrição
modelo_hotspot_xgboost_v1.pkl	models/	Modelo XGBoost treinado e serializado
encoder_municipio.pkl	models/	LabelEncoder do campo município
target_encoding_bairros.json	models/	Score de risco histórico por bairro
stats_bairros.json	models/	Lags e média móvel mais recentes por bairro
bairro_municipio_map.json	models/	Mapeamento bairro → município para filtro na UI
app.py	raiz/	Aplicativo Streamlit principal
requirements.txt	raiz/	Dependências Python do projeto
03_modelagem_preditiva.ipynb	notebooks/	Notebook de treinamento e exportação do modelo

7. Pré-requisitos

7.1 Requisitos de Hardware (Servidor Doméstico)

- Processador: qualquer CPU com suporte a 64 bits (Intel/AMD)
- Memória RAM: mínimo 2 GB disponíveis para o processo Streamlit
- Armazenamento: mínimo 500 MB para o ambiente virtual e artefatos
- Conexão de Internet: banda larga com IP público ou roteamento de porta (port forward) configurado

7.2 Requisitos de Software

- Sistema Operacional: Linux (Ubuntu 22.04+ recomendado) ou Windows Server
- Python 3.10 ou superior
- pip atualizado (pip install --upgrade pip)
- Git (opcional, para clonar o repositório)
- Acesso de administrador para configurar systemd ou equivalente

7.3 Acesso ao Subdomínio

- Domínio principal: https://www.useconectai.com.br/
- Subdomínio do PI5: https://pifatec.useconectai.com.br
- O subdomínio deve apontar (registro A ou CNAME no DNS) para o IP público do servidor doméstico - ainda em processo
- O roteador doméstico deve ter port forwarding configurado da porta 80 ou 8501 para o IP local do servidor

8. Configuração do Ambiente

8.1 Clonar ou copiar o projeto

8.2 Criar o ambiente virtual Python

```
python3 -m venv .venv
```

8.3 Ativar o ambiente virtual

No Linux/macOS:

```
source .venv/bin/activate
```

No Windows:

```
.venv\Scripts\activate
```

8.4 Instalar as dependências

```
pip install --upgrade pip
pip install -r requirements.txt
```

Conteúdo mínimo esperado no requirements.txt:

```
streamlit>=1.30.0
scikit-learn>=1.3.0
xgboost>=2.0.0
joblib>=1.3.0
numpy>=1.24.0
pandas>=2.0.0
```

8.5 Verificar os artefatos do modelo

Confirmar que os arquivos abaixo existem na pasta models/ antes de iniciar o app:

```
ls models/
# Esperado: modelo_hotspot_xgboost_v1.pkl  encoder_municipio.pkl
#           target_encoding_bairros.json  stats_bairros.json  bairro_municipio_map.json
```

9. Execução Local (Desenvolvimento e Testes)

Com o ambiente virtual ativado, executar na raiz do projeto:

```
streamlit run app.py
```

O Streamlit iniciará o servidor e exibirá o endereço de acesso local:

```
Local URL: http://localhost:8501
Network URL: http://[IP-LOCAL]:8501
```

Abrir o endereço Local URL no navegador para verificar o funcionamento da interface antes de expor ao subdomínio público.

10. Deploy no Servidor Doméstico

10.1 Execução em segundo plano com systemd (Linux)

Para garantir que o aplicativo reinicie automaticamente em caso de falha ou reinicialização do servidor, recomenda-se criar um serviço systemd.

Criar o arquivo de serviço:

```
sudo nano /etc/systemd/system/pifatec.service
```

Conteúdo do arquivo:

```
[Unit]
Description=PI5 Fatec — Predição de Hotspots VCM
After=network.target

[Service]
User=[usuario-do-servidor]
WorkingDirectory=/caminho/para/ProjetoIntegrador5
```

```
ExecStart=/caminho/para/.venv/bin/streamlit run app.py \
        --server.port=8501 \
        --server.address=0.0.0.0 \
        --server.headless=true
Restart=always
RestartSec=5

[Install]
WantedBy=multi-user.target
```

Ativar e iniciar o serviço:

```
sudo systemctl daemon-reload
sudo systemctl enable pifatec
sudo systemctl start pifatec
```

Verificar status do serviço:

```
sudo systemctl status pifatec
```

10.2 Configuração de Port Forward no Roteador

Para que o subdomínio pifatec.useconectai.com.br seja acessível externamente, o roteador doméstico deve redirecionar as requisições da porta 443 (HTTPS) para a porta 8501 do servidor.

10.3 Endereço de acesso

https://pifatec.useconectai.com.br

11. Variáveis de Ambiente

Variável de Ambiente	Descrição	Exemplo
MODELS	Caminho para a pasta de modelos	./models
STREAMLIT_SERVER_PORT	Porta em que o Streamlit escuta requisições	8501
STREAMLIT_SERVER_ADDRESS	Endereço de bind do servidor	0.0.0.0

Nota: o aplicativo atual (app.py) não requer configuração de variáveis de ambiente obrigatórias, os caminhos são resolvidos automaticamente a partir do diretório do script. As variáveis acima são opcionais e podem ser definidas no arquivo de serviço systemd se necessário.

12. Segurança

- O arquivo credenciais.json (chave de serviço do BigQuery) não deve ser versionado em repositórios públicos, incluir no .gitignore
- Não há autenticação de usuários no app atual, acesso é público e irrestrito, adequado ao contexto acadêmico
- Os dados utilizados são públicos (SSP-SP) e anonimizados em nível de bairro, não há exposição de dados pessoais de vítimas

13. Monitoramento

O que monitorar	Ferramenta sugerida	Frequência
Uptime do servidor / app	UptimeRobot (gratuito) ou ping manual	Contínuo
Acesso ao subdomínio	Logs do servidor web (nginx/caddy)	Diário
Tempo de resposta da predição	Logs do Streamlit	Semanal
Distribuição das predições	Análise manual dos logs	Mensal
Disponibilidade de novos dados SSP	Consulta manual ao portal SSP-SP	Semestral

Para visualizar os logs do serviço em tempo real:

```
sudo journalctl -u pifatec -f
```

14. Atualização do Modelo

14.1 Quando re-treinar

- Ao dispor de dados mais recentes da SSP-SP (novos anos/meses de ocorrências)
- Caso a distribuição das predições se afaste significativamente do esperado (drift)
- Ao adicionar novos municípios ou bairros ao escopo do sistema

14.2 Processo de atualização

- Atualizar os dados no BigQuery via notebook 01_etl.ipynb
- Re-executar o notebook 03_modelagem_preditiva.ipynb completamente
- Os artefatos na pasta models/ serão sobrescritos automaticamente ao executar as células de exportação

- Reiniciar o serviço no servidor:

```
sudo systemctl restart pifatec
```

- Verificar métricas do novo modelo antes de disponibilizar em produção

14.3 Versionamento de modelos

O arquivo modelo_hotspot_xgboost_v1.pkl segue nomenclatura com sufixo de versão (_v1, _v2...). Recomenda-se manter a versão anterior como backup antes de substituir, copiando para modelo_hotspot_xgboost_v1_backup.pkl.

15. Testes

15.1 Teste de smoke (fumaça) — verificação básica

Após o deploy, acessar o subdomínio e realizar as seguintes verificações manuais:

- A interface carrega corretamente com título e campos de seleção visíveis
- O dropdown de municípios exibe Sorocaba e Votorantim
- Ao selecionar um município, o dropdown de bairros atualiza corretamente
- Clicar em Analisar Risco retorna um resultado com barra de probabilidade
- O resultado varia ao trocar bairro ou mês (o modelo não retorna sempre o mesmo valor)

15.2 Teste de predição de referência

Selecionar o bairro com maior histórico de ocorrências (identificado no notebook como o bairro top) para o mês de maior volume histórico e verificar se o resultado retorna Alto Risco ou Risco Crítico. Esse teste valida que o modelo está carregado corretamente e funcionando conforme esperado.

15.3 Teste de robustez

- Testar bairros com poucos registros históricos — esperado: resultado com probabilidade baixa
- Testar meses historicamente menos violentos — esperado: probabilidade menor que meses de pico
- Testar ano futuro (2030) — o modelo deve retornar resultado sem erros, pois o ano é uma feature numérica

16. Desempenho do Modelo em Produção

As métricas abaixo foram obtidas no conjunto de teste (25% dos dados, estratificado) durante o treinamento documentado no notebook 03_modelagem_preditiva.ipynb:

Métrica	Valor	Interpretação
Acurácia	89,36%	Alta — porém inflada pelo desbalanceamento de classes
Precisão	30,03%	30% dos alertas emitidos correspondem a hotspots reais
Recall	43,76%	O modelo detecta 44% dos hotspots reais existentes
F1-Score	35,62%	Equilíbrio entre Precisão e Recall
AP CV-5	33,18%	Métrica principal — Average Precision em validação cruzada 5 folds
ROC-AUC	79,99%	Boa capacidade discriminatória — 80% de chance de ordenar corretamente

Interpretação para uso em produção: o ROC-AUC de 80% indica boa capacidade de ordenação de risco, o modelo é útil para priorizar bairros para atenção, mas não deve ser usado como sistema de alerta automático sem revisão humana. Resultados devem ser interpretados como apoio à decisão, não como diagnóstico definitivo.

17. Riscos e Mitigações

Risco	Probabilidade	Impacto	Mitigação
Servidor doméstico fora do ar	Média	Alto	Monitoramento de uptime; reinício automático com systemd
Dados desatualizados (drift)	Alta	Médio	Re-treinamento periódico com dados mais recentes da SSP-SP
Consumo de memória excessivo	Baixa	Médio	Cache via @st.cache_resource já implementado no app.py
Modelo com viés geográfico	Média	Alto	Uso restrito a Sorocaba e Votorantim, não generalizar
Interpretação incorreta do resultado	Alta	Alto	Aviso explícito na interface: resultado é de apoio, não diagnóstico

18. Responsáveis

Nome	Função	Contato
Débora Kocks Nogueira		debora.nogueira@aluno.cps.sp.gov.br
Giovana Perugini Guenka		giovana.guenka@aluno.cps.sp.gov.br
Stefanie Mayumi Inacio Kobayashi		stefanie.kobayashi@aluno.cps.sp.gov.br
Vitória Lisauskaz Ferraz da Silva		vitoria.silva14@aluno.cps.sp.gov.br

19. Aprovação

Nome	Cargo / Função	Data	Assinatura
	Orientador(a)	___/___/2026	
	Coordenador(a)	___/___/2026	