Centro Paula Souza

Faculdade de Tecnologia de Votorantim

Curso Superior de Tecnologia em

Ciência de Dados para Negócios

PROJETO INTEGRADOR V

Modelagem Preditiva de Ocorrências de Violência Contra Mulher em Sorocaba

DÉBORA KOCKS NOGUEIRA

GIOVANA PERUGINI GUENKA

STEFANIE MAYUMI KOBAYASHI RESENDE

VITÓRIA LISAUSKAS FERRAZ DA SILVA

JUNHO/2025

SUMÁRIO

1. Introdução **3**
2. Apresentação da Empresa **5**
3. Análise do Cenário, Diagnóstico e Identificação de Problemas **6**
3.1 Alinhamento com Objetivos Estratégicos da Instituição 7
4. Metodologia de Desenvolvimento e Fonte de Dados **7**
4.1 Pipeline de Dados (Proposta de ETL) 8
4.2 Análise Exploratória e Compreensão dos Dados 9
5. Desenvolvimento do Modelo **9**
5.1 Arquitetura do Sistema Proposto 11
5.2 Funcionalidades Implementadas 11
5.3 Fluxo do Usuário e Experiência (UX/UI) 12
5.4 Metodologia de Desenvolvimento e Ferramentas Utilizadas 12
6. Testes e Validações **13**
6.1 Testes Funcionais e Técnicos 13
6.2 Análise dos Resultados 14
6.3 Indicadores de Sucesso e Próximos Passos 14
Conclusão **15**
Referências **15**

1. Introdução

O Projeto Integrador IV, desenvolvido pelo grupo (Débora Kocks, Giovana Guenka, Stefanie Mayumi e Vitória Lisauskas) no 4º semestre do curso “Ciência de Dados Aplicada à Negócios”, oferecido pela Fatec Votorantim, teve como principal proposta o desenvolvimento de um Painel Público de Dados interativo, a partir das aplicações técnicas de ETL (Extrair, Transformar e Carregar) para a tratamento e análise de dados públicos provenientes da SSP (Secretaria de Segurança Pública do Estado de São Paulo).

A fim de continuar o legado, o Projeto Integrador V propõe aos alunos a elaboração de um Modelo de Análise Preditiva, a partir dos dados da empresa/ instituição parceira. Nesse sentido, o grupo procurou a unidade da Delegacia de Defesa da Mulher (DDM) de Sorocaba para avaliar a possibilidade de prosseguir com a temática do projeto anterior. Devido a morosidade burocrática experienciada nas semanas seguintes à Proposição Inicial realizada durante a primeira reunião de contato com os stakeholders envolvidos, em parte pela impossibilidade imediata de extrair dados sensíveis pertencentes à DDM de Sorocaba sem a formalização de inclusão na Rede de Enfrentamento à Violência, e em outra pela escassez de informações necessárias para o desenvolvimento de um Modelo Preditivo com inferências mais específicas (tais como o histórico dos Registros de Ocorrência), foi necessário estabelecer uma alternativa de desenvolvimento do Projeto.

A proposição inicial do projeto consistia em identificar precocemente os casos com maior potencial de escalada para violência letal, utilizando variáveis explicativas que compusessem o cenário de cada ocorrência. No entanto, não houve a possibilidade de acesso à esta granularidade dos dados. Como alternativa, a modelagem preditiva desenvolvida no PI 5 propõem-se a prever a probabilidade de uma nova ocorrência acontecer em determinado bairro, considerando seu histórico. Em outras palavras, identificar os hotspots de violência contra a mulher a partir de dados históricos da SSP-SP.

Entre as principais funcionalidades desenvolvidas, destacam-se: previsão de risco por bairro e período, classificação automática de hotspots, análise temporal de ocorrências e a geração de indicadores preditivos. Para cada cenário, há 4 categorias de classificação: “ Baixo Risco”, “Atenção”, “Alto Risco” e “Risco Crítico”. Durante as fases de teste e validação, o modelo foi capaz de identificar padrões e contribuir para uma validade estatística satisfatória em suas previsões, portanto o modelo conseguiu refletir a realidade em suas estimativas.

Como planejamento futuro e aprimoramento do modelo, seria ideal o acesso aos dados que ampliem a base histórica, a integração de novas fontes de informações, inclusive com sistemas institucionais (SSP ou mesma DDM de Sorocaba). Dessa forma, o projeto poderia ser incorporado às rotinas de segurança, e continuar auxiliando as tomadas de decisões que impactam diretamente à sociedade civil, sobretudo as mulheres sorocabanas.

2. Apresentação da Empresa

A Secretaria de Segurança Pública do Estado de São Paulo (SSP-SP) e a Delegacia de Defesa da Mulher (DDM) de Sorocaba atuam no setor público, especificamente no segmento de segurança governamental e justiça.A SSP- SP tem como principal eixo funcional a proposição, “implementação, coordenação, monitoramento e avaliação política e estatual de segurança pública e defesa social. Também responsabiliza-se por incentivar e apoiar programas de prevenção à criminalidade”.

A Delegacia da Mulher de Sorocaba (DDM), por sua vez, opera como uma unidade operacional local vinculada à Polícia Civil, oferecendo serviços de acolhimento humanizado, registro de ocorrências, solicitação de medidas protetivas de urgência e investigação técnica de crimes de violência doméstica, familiar e sexual contra a mulher.

Desde o início deste projeto, o grupo estabeleceu contato direto com a DDM de Sorocaba, por intermédio da delegada titular Renata Zanin. Assim como buscamos informações em órgãos públicos via solicitação direta pelos canais oficiais fornecidos à população.

3. Análise do Cenário, Diagnóstico e Identificação de Problemas

O cenário da violência contra a mulher no Brasil revela uma crescente e preocupante escalada. De acordo com o Relatório Anual Socioeconômico da Mulher (Raseam) de 2025, foram registradas no Sistema de Informação de Agravos de Notificação (SINAN) 302.856 notificações de violência doméstica, sexual e outras formas de violência contra mulheres no ano de 2023, o que representa um aumento significativo em comparação ao ano de 2022 onde foi observado um registro de 216.024 notificações. Embora o debate nacional seja robusto, a disponibilidade pública e acessível desses dados frequentemente se restringe a contextos regionais, estaduais ou nacionais, falhando em prover a granularidade necessária para intervenções localizadas.

Embora as cidades de Sorocaba e Votorantim tenham instituições públicas que promovem apoio, orientação e proteção às mulheres, existe uma defasagem na utilização de ferramentas tecnológicas para suporte em rotinas de segurança pública. Nem sempre há integração com bases de dados, algumas atualizações das ocorrências são realizadas em planilhas manuais, e a manutenção e monitoramento dependem de análises menos robustas, porém de fácil interpretabilidade. Os municípios enfrentam desafios semelhantes quanto à fragmentação e falta de padronização das informações, o que dificulta a análise integrada e o acompanhamento dos casos.

Diante deste cenário, o Projeto Integrador 5 enfrentou dificuldades em prosseguir com a proposição inicial sugerida, cuja pergunta central seria “dada uma ocorrência de Ameaça registrada hoje, qual a probabilidade de esse mesmo vínculo (vítima/agressor) gerar uma Lesão Corporal ou Feminicídio nos próximos 180 dias?". A dependência da qualidade dos dados oficiais, o difícil acesso aos dados integrais, mesmo com a intenção de cooperação institucional, não foram o suficiente para seguir a linha de pesquisa.

Ainda sim, usufruindo das informações disponíveis da Secretaria de Segurança Pública do Estado de São Paulo, foi possível a extensão e continuação do Projeto Integrador 4. Logo, em parte, este trabalho reaproveita as variáveis disponíveis

para compor um modelo de Análise Preditiva, considerando as limitações intrínsecas já conhecidas.

A premissa reformulada para este projeto, portanto, visa responder a pergunta “qual a probabilidade de uma nova ocorrência acontecer no bairro X, dado o histórico de ocorrências para um mesmo período, naquele local?”. Desse forma, o estabelecimento de hotspots e suas probabilidades de risco auxiliariam a tomada de decisão para a implementação de políticas públicas regionalizadas, assim como contribuir para as rotinas de monitoramento dos agentes da DDM de Sorocaba.

3.1 Alinhamento com Objetivos Estratégicos da Instituição

As documentações elaboradas desde o início do projeto que estabelecem a relação do grupo com os stakeholders formalizam o contato e o interesse multilateral envolvido entre as alunas, a Fatec e a Instituição. Entre eles estão as Atas de Reuniões, Formulários de Proposição e a Solicitação de Cooperação Institucional.

A colaboração das partes envolvidas forneceu ao projeto novas perspectivas e fontes de contato futuro para que a solução exercida neste projeto seja aprimorada.

4. Metodologia de Desenvolvimento e Fonte de Dados

O desenvolvimento do projeto foi estruturado com base em um pipeline de Ciência de Dados, contemplando etapas de extração, transformação, análise exploratória, modelagem preditiva e planejamento de implantação. A solução foi construída utilizando Python, Google BigQuery, XGBoost e Streamlit.

4.1 Pipeline de Dados (Proposta de ETL)

Os dados utilizados no projeto foram obtidos a partir das bases públicas da Secretaria de Segurança Pública do Estado de São Paulo (SSP-SP), contendo registros relacionados às ocorrências atendidas pelas Delegacias de Defesa da Mulher (DDM) de Sorocaba e Votorantim.

O pipeline ETL foi implementado em Python e organizado de forma modular, permitindo reprodutibilidade e escalabilidade. A etapa de extração foi responsável pelo download automatizado dos arquivos XLSX disponibilizados pela SSP-SP. Em seguida, os dados foram consolidados em um único DataFrame para padronização estrutural.

Durante a etapa de transformação, foram realizadas atividades de limpeza e preparação dos dados, incluindo:

• tratamento de valores nulos;

• remoção de registros inconsistentes;

• padronização textual;

• conversão de datas;

• criação de variáveis temporais;

• normalização de categorias;

• engenharia de atributos para modelagem preditiva.

Os dados tratados foram armazenados no Google BigQuery, utilizado como Data Warehouse central do projeto. Essa abordagem permitiu maior organização, facilidade de consulta e integração entre as etapas analíticas.

O pipeline também incorporou técnicas de Feature Engineering, como:

• criação de variáveis de atraso temporal (lags);

• médias móveis;

• codificação estatística de bairros via Target Encoding;

• construção de cenários negativos utilizando Negative Sampling.

A utilização de Negative Sampling teve como objetivo reduzir o viés de seleção, simulando cenários sem ocorrências registradas e permitindo melhor balanceamento do modelo.

4.2 Análise Exploratória e Compreensão dos Dados

A análise exploratória de dados (EDA) foi conduzida com o objetivo de compreender os padrões espaciais e temporais das ocorrências de violência contra a mulher nas cidades analisadas.

Foram utilizados gráficos estatísticos, distribuições temporais e análises de frequência para identificar tendências relevantes. Os notebooks demonstraram aumento significativo no volume de ocorrências em determinados períodos do ano, além de concentração geográfica em regiões específicas.

As análises contemplaram:

• evolução temporal das ocorrências;

• distribuição por tipo criminal;

• análise de bairros com maior incidência;

• padrões por dia da semana;

• distribuição por horário;

• identificação de hotspots.

Os gráficos gerados permitiram identificar concentração elevada de registros em determinados bairros e padrões temporais recorrentes, fatores fundamentais para a construção das variáveis utilizadas no modelo preditivo.

Além disso, a análise exploratória revelou a necessidade de tratamento adicional em variáveis categóricas e registros incompletos, contribuindo diretamente para o refinamento do pipeline de preparação dos dados.

5. Desenvolvimento do Modelo

O desenvolvimento da solução preditiva teve como foco principal a identificação de hotspots de violência contra a mulher a partir de dados históricos da SSP-SP.

O modelo selecionado para implementação foi o XGBoost Classifier, escolhido devido à sua capacidade de lidar com dados heterogêneos, relações não lineares e grande volume de variáveis categóricas.

O processo de modelagem incluiu:

• separação entre dados de treino e teste;

• validação temporal;

• balanceamento de classes;

• ajuste de hiperparâmetros;

• avaliação comparativa entre abordagens.

Foram utilizadas técnicas avançadas de engenharia de atributos, incluindo:

• variáveis temporais;

• lags mensais e anuais;

• médias móveis;

• Target Encoding;

• indicadores de reincidência regional.

A modelagem foi conduzida utilizando as bibliotecas Scikit-Learn e XGBoost, integradas ao ambiente Python.

5.1 Arquitetura do Sistema Proposto

A arquitetura da solução foi organizada em quatro camadas principais:

1. Camada de Coleta:

Responsável pela obtenção automatizada dos dados públicos da SSP-SP.

2. Camada de Processamento:

Responsável pelas etapas de ETL, limpeza, transformação e engenharia de atributos.

3. Camada de Modelagem:

Responsável pelo treinamento, validação e inferência do modelo preditivo.

4. Camada de Visualização:

Implementada em Streamlit, permitindo consultas interativas e visualização da classificação de risco preditivo.

O sistema foi planejado visando futura implantação em ambiente de produção, com possibilidade de integração em serviços web e APIs.

5.2 Funcionalidades Implementadas

Entre as principais funcionalidades implementadas destacam-se:

• previsão de risco por bairro e período;

• classificação automática de hotspots;

• análise temporal de ocorrências;

• geração de indicadores preditivos;

• interface visual interativa;

• consulta dinâmica por município e período.

O sistema classifica os cenários em quatro níveis de risco:

• Baixo Risco;

• Atenção;

• Alto Risco;

• Risco Crítico.

5.3 Metodologia de Desenvolvimento e Ferramentas Utilizadas

O projeto foi desenvolvido utilizando metodologia ágil baseada em sprints, organizadas por meio da ferramenta ClickUp.

As principais tecnologias utilizadas foram:

• Python 3.9+;

• Pandas;

• NumPy;

• Scikit-Learn;

• XGBoost;

• Google BigQuery;

• Streamlit;

• Matplotlib;

• Seaborn.

A organização do projeto foi estruturada em notebooks específicos para ETL, análise exploratória e modelagem preditiva, garantindo modularidade e rastreabilidade das etapas.

5.4 Desafios e Estratégias de Mitigação

Durante o desenvolvimento, foram identificados desafios relacionados à qualidade e disponibilidade dos dados públicos.

Entre os principais desafios, destacam-se:

• registros incompletos;

• inconsistências categóricas;

• ausência de padronização em determinadas variáveis;

• desbalanceamento de classes;

• limitação temporal dos registros históricos.

Para mitigação desses problemas, foram aplicadas técnicas de limpeza, balanceamento e engenharia de atributos, além da utilização de Negative Sampling para redução de viés.

6. Testes e Validações

Os testes realizados tiveram como objetivo validar a consistência da solução preditiva, bem como verificar a capacidade do modelo em identificar padrões relevantes relacionados à violência contra a mulher.

Foram aplicadas métricas de avaliação compatíveis com problemas de classificação, utilizando validação temporal e comparação entre conjuntos de treino e teste.

6.1 Testes Funcionais e Técnicos

Os testes funcionais verificaram:

• integridade do pipeline ETL;

• consistência das consultas ao BigQuery;

• execução do modelo preditivo;

• estabilidade da interface Streamlit;

• funcionamento das classificações de risco.

Também foram realizados testes técnicos relacionados ao desempenho do modelo e tempo de processamento.

6.2 Análise dos Resultados

Os resultados demonstraram que o modelo foi capaz de identificar padrões relevantes de concentração de ocorrências, contribuindo para a previsão de regiões com maior probabilidade de incidência futura.

A utilização de variáveis temporais e Target Encoding contribuiu significativamente para o desempenho do modelo, permitindo maior sensibilidade na identificação de hotspots.

Além disso, a análise exploratória confirmou padrões recorrentes relacionados a sazonalidade, bairros críticos e períodos de maior incidência.

6.3 Indicadores de Sucesso e Próximos Passos

Como indicadores de sucesso do projeto, destacam-se:

• construção de pipeline automatizado;

• consolidação de ambiente analítico em BigQuery;

• desenvolvimento de modelo preditivo funcional;

• criação de interface interativa para consulta;

• estruturação de solução potencialmente implantável em ambiente real.

Como próximos passos:

• ampliação da base histórica;

• integração de novas fontes de dados;

• refinamento contínuo do modelo;

• implantação em ambiente de produção;

• integração com sistemas institucionais da SSP-SP.

Conclusão

O Projeto Integrador V, dando continuidade ao pipeline de dados estruturado no semestre anterior, demonstrou a adaptação às limitações práticas impostas pela sensibilidade e pelas restrições legais de acesso aos dados nominais. A transição da proposta inicial, que visava prever a escalada letal de casos individuais com base no vínculo vítima/agressor, para a identificação preditiva de *hotspots* permitiu a viabilização do projeto e reiterou o compromisso do grupo em entregar uma ferramenta analítica funcional e aplicável à realidade da Delegacia de Defesa da Mulher (DDM).

Para transpor as barreiras da fragmentação das informações e da falta de granularidade, estruturou-se um pipeline de *Machine Learning*. A utilização dos dados abertos da SSP-SP, aliada a técnicas avançadas de engenharia de atributos (como *Target Encoding* e *Negative Sampling*) e à escolha do algoritmo XGBoost, permitiu o treinamento de um modelo preditivo consistente e alinhado aos desafios de desbalanceamento das classes. A arquitetura de dados implementada, que abrangeu desde o armazenamento em nuvem via Google BigQuery até a criação de uma interface interativa no Streamlit, consolidou-se em um sistema capaz de classificar preventivamente o risco de novas ocorrências em quatro níveis: Baixo Risco, Atenção, Alto Risco e Risco Crítico.

A capacidade de prever bairros e períodos de maior vulnerabilidade atende diretamente a uma dor latente identificada no diagnóstico inicial: a necessidade de ferramentas tecnológicas que possibilitem o direcionamento assertivo e preventivo dos recursos humanos e logísticos dos agentes de segurança.

Em conclusão, o modelo preditivo desenvolvido estabelece um marco importante para a utilização da Ciência de Dados como instrumento de impacto social na região. No entanto, o aprimoramento contínuo dessa solução depende intrinsecamente do estreitamento da cooperação institucional para a ampliação da base histórica e acesso a dados mais granulares.

Referências

Base dos Dados - Conjuntos de dados abertos. Disponível em: <https://basedosdados.org/dataset/f51134c2-5ab9-4bbc-882f-f1034603147a?table=7d2d29c1-cfa8-470b-ab13-a83cf522c5ac> . Acesso em: 10 mar 2026

Secretaria de Segurança Pública do Estado de São Paulo. Institucional: Funções e Competências. Disponível em: https://www.ssp.sp.gov.br/institucional/funcoes-e-competencias). Acesso em 09 mai. 2026

Portal SSP. Disponível em: <https://www.ssp.sp.gov.br/estatistica/consultas> . Acesso em: ago. 2025.

RASEAM 2025 Relatório Anual Socioeconômico da Mulher. : [2025]. Disponível em: <https://www.gov.br/mulheres/pt-br/central-de-conteudos/publicacoes/raseam-2025.pdf>. Acesso em: 14 mai 2026