Avaliação 1 – Direito Digital (PI6)

Sep 28, 2026 · @May

Disciplina: Direito Digital – Profa. Evelyn Sola

Grupo: Débora Kocks Nogueira e Stefanie Mayumi Inácio Kobayashi Resende

Projeto: PI6 – Classificação Histórica de Ocorrências de Violência Contra a Mulher em Sorocaba e Votorantim (Fatec Votorantim, CST em Ciência de Dados para Negócios)

As respostas se baseiam no relatório do PI6, no Deploy Guide, no Guia de Uso, na ata de contato com a Profa. Evelyn, no documento de identificação dos agentes da LGPD e no código dos notebooks do projeto (00 a 05).

1. Tipos de dados, dados pessoais e dados sensíveis

O PI trabalha com três fontes. Apenas os microdados da SSP-SP são dados pessoais, e parte deles deve ser tratada como dado sensível.

Fonte	Conteúdo usado	Dado pessoal?
SSP-SP (planilhas SPDadosCriminais, 2022–2026)	2.456 registros das DDMs de Sorocaba e Votorantim, com 16 colunas: número do BO, município, delegacia, ano, mês, data, hora, período, dia da semana, tipo de local, bairro, logradouro, latitude, longitude, rubrica e natureza da ocorrência	Sim, identificável
IBGE – Censo 2022	Idade média, taxa de alfabetização, % de domicílios chefiados por mulheres e moradores por domicílio, agregados por setor censitário e somados por zona	Não, dado agregado
OpenStreetMap	Geometria dos bairros, usada para montar as zonas Norte, Sul, Leste, Oeste e Centro	Não, dado geográfico

São dados pessoais? Sim. Os microdados da SSP não trazem o nome da vítima, mas o art. 5º, I define dado pessoal como informação relacionada a pessoa natural "identificada **ou identificável**". A combinação de número do BO, data, hora, logradouro e coordenadas com

o local "Residência" (2.063 registros) pode apontar para a casa de uma vítima específica. Pelo art. 12, o dado só deixa de ser pessoal se não puder ser revertido "com esforços razoáveis". Aqui, bastaria cruzar com notícias locais ou com o conhecimento de vizinhos.

E se a análise é por zona? A agregação por zona não afasta a LGPD, porque ela acontece depois que os registros individuais já foram baixados, armazenados e processados. Pelo art. 5º, X, coleta, armazenamento e processamento são formas de tratamento. É preciso separar duas camadas:

- **dados de entrada** (microdados da SSP-SP, na tabela `ocorrencias_ddm`): são dados pessoais identificáveis e estão sujeitos à LGPD;
- **resultados agregados por zona** (taxa, classe histórica e perfis usados no modelo): não são dados pessoais, porque cobrem 10 zonas com dezenas de milhares de habitantes cada, com o corte mínimo de 5 ocorrências, e não permitem chegar a uma vítima.

A agregação por zona é, portanto, a medida de anonimização dos resultados, detalhada na questão 2.

São dados sensíveis? O rol do art. 5º, II não cita "vítima de crime". Mesmo assim, parte dos dados deve ser tratada como sensível:

- estupro e estupro de vulnerável se referem à **vida sexual**;
- lesão corporal dolosa (1.712 registros) se refere à **saúde** e à integridade física.

Além disso, estupro de vulnerável (434 registros) envolve, em regra, vítimas menores de 14 anos. Por isso também incide o **art. 14**, que exige que o tratamento de dados de crianças e adolescentes atenda ao melhor interesse deles.

A titular dos dados é a vítima da ocorrência. O controlador é o Estado de São Paulo, por meio da SSP-SP, conforme o documento de identificação dos agentes da LGPD do grupo.

2. Anonimização ou pseudonimização

Os dados chegam pseudonimizados pela SSP-SP e são anonimizados pelo grupo nos resultados, por agregação. A tabela intermediária ainda precisa de ajustes.

Na origem. A SSP-SP publica as planilhas sem nome da vítima e sem nome do agressor. Isso é uma pseudonimização feita pelo controlador, e não uma anonimização. A "chave" do art. 13, § 4º é o **número do BO**, que permite recuperar o boletim completo no sistema da Polícia Civil. Essa chave fica com a SSP-SP e a Polícia Civil, em ambiente controlado. O grupo não tem acesso ao boletim completo.

Nos resultados do PI. A anonimização acontece por agregação:

- toda a análise e a modelagem trabalham com 10 zonas, cada uma com dezenas de milhares de habitantes;

- zonas com menos de 5 ocorrências no período são marcadas como "dados insuficientes" e não são classificadas (regra `MIN_OCORRENCIAS_ZONA = 5`, notebook 03);
- o modelo recebe só percentuais e indicadores por zona, nunca um registro individual.

O que ainda falta. A tabela `pi6.dados_ssp_zonas.ocorrencias_ddm` guarda `codigo_bo`, `logradouro`, `latitude` e `longitude`. Essa camada ainda não foi pseudonimizada pelo grupo. As medidas previstas são:

1. substituir o `codigo_bo` por um hash com "sal" (salt), guardado separadamente;
2. mover logradouro, latitude e longitude para uma tabela separada, num schema restrito, com permissão (`GRANT`) apenas para as pessoas autorizadas;
3. manter na tabela analítica apenas município, bairro/zona, mês/ano, período e natureza da ocorrência.

Pessoas autorizadas a acessar a chave:

Informação	Quem acessa
Chave original (BO completo)	Servidores da SSP-SP e da Polícia Civil com acesso ao sistema de registro de ocorrências. Encarregado do Estado: Valmir Gomes Dias
Tabela restrita no Databricks (hash do BO, logradouro, coordenadas)	Somente Débora Kocks Nogueira e Stefanie Mayumi Inácio Kobayashi Resende

3. Finalidade de uso e base legal

A finalidade é pesquisa acadêmica, enquadrada como estudo por órgão de pesquisa (art. 7º, IV e art. 11, II, "c").

Finalidade. Descrever a distribuição histórica das ocorrências de violência contra a mulher por zona de Sorocaba e Votorantim, normalizada pela população (taxa por 10 mil habitantes), como apoio à priorização interna da DDM de Sorocaba. Ficam fora da finalidade:

- prever casos futuros, motivo pelo qual o termo "previsão de risco" foi abandonado;
- identificar vítimas ou agressores;
- qualquer uso comercial.

Enquadramento legal.

- **Art. 4º, II, "b":** o tratamento para fins exclusivamente acadêmicos continua sujeito aos arts. 7º e 11.
- **Art. 7º, IV e art. 11, II, "c":** realização de estudos por órgão de pesquisa, com anonimização sempre que possível. A Fatec/Centro Paula Souza é instituição pública de ensino e pesquisa, e o PI tem vínculo formal com a instituição e com o orientador.
- **Art. 7º, §§ 3º e 7º:** como os dados são de acesso público, o tratamento deve respeitar a finalidade, a boa-fé e o interesse público que justificaram sua divulgação, ou seja, a transparência das estatísticas de segurança pública. O uso do projeto é compatível com isso.

Bases descartadas. O consentimento é inviável, porque o grupo não consegue identificar nem contatar as titulares. O legítimo interesse não serve para dados sensíveis, pois não está entre as hipóteses do art. 11.

4. Os 10 princípios do art. 6º no projeto

Cada princípio do art. 6º corresponde a uma decisão concreta do PI6.

Princípio	Como se aplica no PI6
I – Finalidade	Propósito acadêmico, descritivo e declarado no relatório. Os dados não são reutilizados para fins incompatíveis, como previsão individual ou uso comercial.
II – Adequação	Estatística agregada por zona, coerente com o motivo pelo qual a SSP-SP publica os dados (transparência).
III – Necessidade	Filtro apenas das DDMs dos dois municípios e de 16 colunas, sem dados sobre a pessoa; resultados agregados. Número do BO, logradouro e coordenadas não são necessários ao resultado final e serão retirados (questão 5).
IV – Livre acesso	O grupo não consegue identificar titulares. Diante de um pedido de acesso, o art. 18, § 4º, I permite indicar a SSP-SP como agente responsável. A metodologia é pública.
V – Qualidade dos dados	Limitações documentadas: 398 registros (16,2%) sem zona, 571 sem horário e subnotificação. Bairros normalizados por regras e fuzzy matching; população do Censo 2022.

Princípio	Como se aplica no PI6
VI – Transparência	Relatório, Deploy Guide, Guia de Uso e README explicam fontes, cálculos, tercis (P33 = 23,44 e P67 = 30,95) e o que o resultado não significa.
VII – Segurança	Dados no Databricks com Unity Catalog; repositório sem dados e com `.gitignore` para credenciais; proibição de senhas e tokens nos notebooks. Melhorias nas questões 5 e 6.
VIII – Prevenção	Mínimo de 5 ocorrências por zona; classificação relativa, sem previsão; mapa de pontos não divulgado.
IX – Não discriminação	Rotular publicamente uma zona como "Alto" pode estigmatizar moradores. O resultado é recomendado como insumo interno de priorização. Não há variáveis individuais de raça ou renda.
X – Responsabilização e prestação de contas	Decisões registradas nos documentos, no MLflow (parâmetros e métricas) e em atas, incluindo a orientação jurídica pedida à Profa. Evelyn em 14/09/2026.

5. Minimização de dados na prática

O grupo já reduziu as fontes a 16 colunas e agregou tudo por zona. Ainda falta retirar da tabela analítica os campos que localizam a vítima.

Medidas já adotadas:

- a extração lê as planilhas da SSP-SP e descarta tudo que não é das DDMs de Sorocaba e Votorantim;
- a seleção final mantém só 16 colunas e descarta as demais, sem nome, idade ou qualquer dado da vítima ou do agressor;
- a unidade de análise mudou de bairro para zona, com populações maiores e menor risco de reidentificação;
- os dados do IBGE entram já agregados por setor censitário;
- existe o limiar mínimo de 5 ocorrências por zona;
- o modelo usa apenas perfis agregados por zona;

- as planilhas brutas são baixadas numa pasta temporária do cluster, e o repositório no GitHub contém apenas código, sem dados.

Limitação de acesso interno. Os dados ficam no Unity Catalog, e apenas as duas integrantes executam os notebooks. O workspace, porém, está vinculado a uma conta institucional compartilhada (`cdnfatecvotorantim@gmail.com`). Com uma conta compartilhada não é possível saber quem acessou o quê. O ideal é usar contas individuais e conceder acesso (`GRANT`) por usuário.

Quem tem acesso a quê:

Recurso	Acesso
Tabelas Delta do schema `pi6.dados_ssp_zonas`	Débora e Stefanie
Tabela restrita com hash do BO, logradouro e coordenadas (a implantar)	Débora e Stefanie
Resultados agregados por zona (relatório, interface, banca)	Público

Ajustes a implementar:

- retirar da tabela analítica `codigo_bo` , `logradouro` , `latitude` , `longitude` e a hora exata, mantendo só o período do dia;
- não incluir o mapa de pontos por coordenadas (notebook 04) no relatório, na interface nem na banca, substituindo-o por um mapa agregado por zona;
- a revisão de formulários de coleta não se aplica, pois o projeto não coleta dados diretamente das titulares: usa apenas bases públicas já publicadas.

Retenção e descarte. Pelo art. 15, I, o tratamento termina quando a finalidade é alcançada, e o art. 16 manda eliminar os dados depois disso. O grupo propõe:

1. manter os dados até a banca final do PI6 e eliminá-los em até 30 dias depois dela;
2. excluir as tabelas com registros individuais usando `DROP TABLE` e `VACUUM` , porque o Delta Lake guarda versões antigas (time travel);
3. conservar apenas os resultados agregados por zona, como permite o art. 16, II para estudo por órgão de pesquisa;
4. registrar a exclusão por escrito, como comprovação.

6. Credenciais, logs e art. 48

O sistema não coleta credenciais de usuários finais. As únicas credenciais são as de acesso da equipe, que são dados pessoais comuns.

Credenciais de usuários. A interface pública (pifatec.useconectai.com.br) não tem login e mostra apenas dados agregados por zona: município, zona, quantidade de ocorrências, população, taxa e classe histórica. Por isso o projeto não coleta credenciais de usuários.

Credenciais da equipe. As credenciais existentes são as de acesso ao Databricks, ao GitHub e ao servidor. São dados pessoais comuns, e não sensíveis, porque e-mail e senha não estão no rol do art. 5º, II. Mesmo assim, exigem as medidas de segurança do art. 46:

- o repositório tem um `.gitignore` que impede versionar arquivos de credenciais (chaves de serviço, certificados e arquivos `.json` de credenciais);
- o Deploy Guide proíbe registrar senhas, tokens ou chaves nos notebooks;
- recomenda-se guardar segredos com `dbutils.secrets`, ativar MFA e usar contas individuais no lugar da conta compartilhada;
- o download das planilhas usa `verify=False`, que desliga a verificação do certificado SSL, e deve ser corrigido.

Logs.

- O Databricks registra acessos e execuções (logs de auditoria e linhagem no Unity Catalog).
- O MLflow registra as execuções dos modelos, sem dados pessoais.
- O servidor da interface pode gravar logs de acesso com IP, que é dado pessoal. Recomenda-se guardar os logs por prazo definido e com acesso restrito.

Art. 48. O controlador deve comunicar à ANPD e aos titulares o incidente que possa gerar risco ou dano relevante. A Resolução CD/ANPD nº 15/2024 fixa o prazo de 3 dias úteis. Como os dados envolvem violência sexual e doméstica, um vazamento teria risco relevante. A SSP-SP, como controladora, tem encarregado nomeado e canal de atendimento, portanto possui a estrutura exigida pelo art. 48.

Em caso de incidente, o procedimento do grupo seria:

1. conter o incidente, revogando acessos e trocando credenciais;
2. avisar imediatamente o orientador e a Fatec/Centro Paula Souza;
3. informar a SSP-SP pelo canal do encarregado;
4. documentar o ocorrido.

Esse procedimento ainda não está formalizado por escrito e foi levado à Profa. Evelyn na ata de 14/09/2026 (dúvida sobre responsabilidade em caso de incidente).