Centro Paula Souza
Faculdade de Tecnologia de Votorantim
Curso Superior de Tecnologia em Ciência de Dados para Negócios

DÉBORA KOCKS NOGUEIRA
STEFANIE MAYUMI INACIO KOBAYASHI

CLASSIFICAÇÃO HISTÓRICA DE OCORRÊNCIAS DE VIOLÊNCIA CONTRA A MULHER EM SOROCABA E VOTORANTIM

Deploy Guide

VOTORANTIM
2026

SUMÁRIO

1 OBJETIVO **3**

2 ESCOPO **3**

3 DEFINIÇÕES E SIGLAS **3**

4 VISÃO GERAL DA SOLUÇÃO **4**

4.1 DESCRIÇÃO DO MODELO 4
4.2 TIPO DE MODELO 5
4.3 PRINCIPAIS CARACTERÍSTICAS DE ENTRADA 5
4.4 FLUXO DA SOLUÇÃO 6

5 ARQUITETURA DA SOLUÇÃO **6**

6 ORGANIZAÇÃO DOS DADOS **6**

7 PRÉ-REQUISITOS **7**

8 CONFIGURAÇÃO DO AMBIENTE DATABRICKS **8**

8.1 WORKSPACE 8
8.2 CATÁLOGO E SCHEMA 8
8.3 EXECUÇÃO DOS NOTEBOOKS 8
8.4 CHAVE DE PSEUDONIMIZAÇÃO 9

9 MLFLOW E REGISTRO DOS EXPERIMENTOS **9**

10 DEPLOY DO DATABRICKS APP **9**

10.1 ESTRUTURA DO APP 10
10.2 PREPARAR AS TABELAS 10
10.3 CRIAR O APP 10
10.4 ENVIAR O CÓDIGO E PUBLICAR 10
10.5 PERMISSÕES DO APP 11
10.6 INICIAR, ACESSAR E PARAR 11
10.7 EXECUTAR LOCALMENTE (DESENVOLVIMENTO) 11

11 TESTES DE DEPLOY **12**

12 ATUALIZAÇÃO DA SOLUÇÃO **12**

13 SEGURANÇA E BOAS PRÁTICAS **13**

14 MONITORAMENTO **13**

15 RESPONSÁVEIS **13**

1 OBJETIVO

Este documento apresenta as orientações para execução e disponibilização da solução desenvolvida no Projeto Integrador 6 (PI6) da FATEC Votorantim, dando continuidade aos projetos integradores anteriores.

A solução foi estruturada em ambiente Databricks e organizada em notebooks responsáveis pelas etapas de zoneamento, integração dos dados, classificação histórica, análise exploratória, modelagem e preparação dos dados da interface, publicada como um Databricks App.

2 ESCOPO

Este documento cobre:

- Arquitetura de implantação da solução no ambiente Databricks;
- Organização dos dados em Delta Lake e Unity Catalog;
- Execução dos notebooks que compõem o pipeline analítico;
- Organização e rastreamento dos experimentos de aprendizado de máquina com MLflow;
- Publicação da interface como Databricks App;
- Testes de acesso e funcionamento do deploy;
- Procedimentos de atualização após alterações na solução.

Não fazem parte deste documento:

- Detalhamento completo da extração e transformação dos dados, que é documentado nos notebooks do projeto;
- Explicação detalhada de cada algoritmo de aprendizado de máquina;
- Hospedagem da interface fora do ambiente Databricks.

3 DEFINIÇÕES E SIGLAS

Quadro 1 – Definições e siglas

Termo / Sigla	Descrição
Databricks	Ambiente central utilizado para processamento, armazenamento, análise e modelagem.
Delta Lake	Formato de armazenamento estruturado utilizado nas tabelas do projeto.

Unity Catalog	Camada de organização e governança dos dados, modelos e demais ativos.
MLflow	Ferramenta utilizada para rastrear parâmetros, métricas, execuções e modelos.
ETL	Extração, Transformação e Carga dos dados.
SSP-SP	Secretaria da Segurança Pública do Estado de São Paulo.
IBGE	Instituto Brasileiro de Geografia e Estatística.
OpenStreetMap	Fonte de dados geográficos utilizada no zoneamento.
Deploy	Processo de publicação da solução para uso; neste projeto, como um Databricks App.
ML	Machine Learning — Aprendizado de Máquina.
DDM	Delegacia de Defesa da Mulher.
Databricks Apps	Recurso do Databricks para publicar aplicações web (neste projeto, em Streamlit) dentro do workspace.
SQL Warehouse	Recurso de computação do Databricks usado pelo app para consultar as tabelas.
Service principal	Identidade de serviço criada para o app, com permissões próprias no Unity Catalog.
Secret scope	Cofre de segredos do Databricks; guarda a chave de pseudonimização.
Streamlit	Biblioteca Python usada para construir a interface.
IPVS	Índice Paulista de Vulnerabilidade Social, da Fundação SEADE.
LGPD	Lei Geral de Proteção de Dados Pessoais (Lei nº 13.709/2018).

Fonte: elaborado pelas autoras (2026).

4 VISÃO GERAL DA SOLUÇÃO

4.1 DESCRIÇÃO DO MODELO

O Projeto Integrador 6 reorganiza a solução desenvolvida nos projetos anteriores em uma arquitetura centralizada no Databricks. A solução integra dados públicos de ocorrências da SSP-SP, dados do Censo 2022 do IBGE, o Índice Paulista de Vulnerabilidade Social (IPVS 2022) da Fundação SEADE e dados geográficos do OpenStreetMap. Os resultados são publicados em um Databricks App.

A análise utiliza zonas territoriais: Norte, Sul, Leste, Oeste e Centro, e calcula a taxa histórica de ocorrências por 10.000 habitantes. A partir da distribuição dessas taxas, as zonas são classificadas em Baixo, Médio e Alto por tercis.

4.2 TIPO DE MODELO

A variável-alvo não é criada pelo modelo. Ela é definida anteriormente a partir da taxa histórica por 10.000 habitantes e da divisão por tercis. Os modelos utilizam essa classificação previamente estabelecida para os experimentos.

Quadro 2 – Características do modelo

Item	Projeto Integrador 6
Problema	Classificação dos perfis históricos das zonas
Variável-alvo	Classificação histórica: Baixo, Médio ou Alto
Modelos	Árvore de Decisão, Random Forest e XGBoost
Base territorial	Zonas Norte, Sul, Leste, Oeste e Centro
Normalização	Taxa histórica por 10.000 habitantes
Rastreamento	MLflow
Avaliação	Leave-one-out e teste de permutação (680 rodadas na execução final, de 15/10/2026)
Modelo registrado	O de maior F1 macro, no Unity Catalog como pi6.dados_ssp_zonas.PI6_ClassificadorPerfilHistoricoZona (XGBoost na execução final)
Interface	Databricks App (Streamlit)

Fonte: elaborado pelas autoras (2026).

4.3 PRINCIPAIS CARACTERÍSTICAS DE ENTRADA

As variáveis utilizadas efetivamente no modelo devem ser mantidas sincronizadas com o notebook de modelagem. Variáveis que compõem diretamente o cálculo da classificação histórica não devem ser reutilizadas como atributos de entrada quando isso provocar vazamento do rótulo.

Na execução final (15/10/2026), o modelo usou seis variáveis, definidas antes de ver o resultado:

Quadro 3 – Variáveis de entrada do modelo

Grupo	Variáveis utilizadas no modelo
Ocorrências	% de registros em residência
Temporais	% de registros à noite (só entre os registros com período informado) e % no sábado ou domingo
Populacionais	Idade média e moradores por domicílio (IBGE, Censo 2022)
Socioeconômicas	% da população em setores de vulnerabilidade alta (IPVS 2022, SEADE)
Não utilizadas	Total de ocorrências e população (formam a taxa: seria vazamento) e município

Fonte: elaborado pelas autoras (2026).

4.4 FLUXO DA SOLUÇÃO

1. Dados públicos da SSP-SP são extraídos e tratados.
2. Dados territoriais e geográficos são utilizados para estruturar as zonas.
3. Dados populacionais do IBGE (Censo 2022) e o IPVS da Fundação SEADE são integrados às zonas.
4. As informações processadas são armazenadas em tabelas Delta no Databricks.
5. A análise exploratória caracteriza a distribuição histórica das ocorrências.
6. A taxa por 10.000 habitantes é calculada para as zonas.
7. Os tercis da distribuição definem as classes históricas Baixo, Médio e Alto.
8. Os modelos de classificação são executados sobre os perfis das zonas.
9. Os experimentos são registrados no MLflow.
10. O notebook 06 prepara tabelas agregadas por zona, e o Databricks App apresenta os resultados a partir delas.

5 ARQUITETURA DA SOLUÇÃO

Quadro 4 – Camadas da arquitetura da solução

Camada	Tecnologia / recurso	Responsabilidade
Fontes de dados	SSP-SP / IBGE / SEADE / OpenStreetMap	Fornecimento das informações utilizadas na análise
Processamento	Databricks	Execução dos notebooks e processamento
Armazenamento	Delta Lake	Persistência das tabelas estruturadas
Governança	Unity Catalog	Organização e controle dos ativos
Modelagem	Scikit-learn / XGBoost	Execução dos modelos de classificação
Experimentos	MLflow	Registro de parâmetros, métricas e modelos
Consulta	SQL Warehouse	Leitura das tabelas pelo app, com permissão só de leitura
Interface	Databricks Apps (Streamlit)	Consulta e visualização dos resultados, só a partir de tabelas agregadas
Segredos	Secret scope pi6	Guarda da chave de pseudonimização dos boletins

Fonte: elaborado pelas autoras (2026).

6 ORGANIZAÇÃO DOS DADOS

A arquitetura do Projeto Integrador 6 utiliza estruturas persistentes no catálogo do Databricks, permitindo que os resultados das etapas de preparação e integração sejam reutilizados.

Os nomes abaixo foram conferidos no ambiente Databricks em 17/10/2026. Entre parênteses, o notebook que grava cada tabela.

Quadro 5 – Estruturas de dados no Unity Catalog

Estrutura	Função
pi6	Catálogo do projeto no Unity Catalog
dados_ssp_zonas	Schema das tabelas analíticas, sem dados identificadores
dados_ssp_zonas_restrito	Schema restrito: correspondência entre pseudônimo e número do BO (mapa_pseudonimo_bo), sem acesso do app
ocorrencias_ddm	Ocorrências tratadas e pseudonimizadas (01)
bairros_zona / setores_zona	Zona de cada bairro do OpenStreetMap e de cada setor censitário (00)
bairros_revisados_zona	Zona dos bairros localizados manualmente por coordenada (00)
referencia_centro_municipio	Ponto central de cada município usado no zoneamento (00)
bairros_ssp_x_zona	Correspondência entre o bairro escrito no boletim e a zona (02)
populacao_zonas	População e indicadores socioeconômicos por zona (02)
taxa_ocorrencias_zonas	Ocorrências e taxa por 10.000 habitantes por zona (02)
classes_historicas_zonas	Classe histórica (Baixo, Médio ou Alto) de cada zona (03)
modelo_resultados, modelo_previsoes_zonas, modelo_permutacoes, modelo_importancias	Resultados da modelagem lidos pelo app (05, Célula 15.1)
painel_ocorrencias_agregadas	Contagens por zona, uma dimensão por vez, lidas pelo app (06)

Fonte: elaborado pelas autoras (2026).

7 PRÉ-REQUISITOS

- Acesso autorizado ao workspace Databricks utilizado pelo projeto;
- Permissões necessárias para execução dos notebooks e consulta às tabelas;
- Acesso ao Unity Catalog e ao schema utilizado pelo projeto;
- Acesso aos experimentos e modelos registrados no MLflow, quando aplicável;
- Permissão para criar e gerenciar apps (Compute → Apps) e um SQL Warehouse disponível para o app;
- Secret scope pi6 com a chave chave_pseudonimizacao (seção 8.4);

- Databricks CLI configurada, para o deploy por linha de comando (opcional).

8 CONFIGURAÇÃO DO AMBIENTE DATABRICKS

8.1 WORKSPACE

O projeto deve estar disponível no workspace Databricks definido para o Projeto Integrador 6. O acesso deve ser validado antes da execução dos notebooks.

8.2 CATÁLOGO E SCHEMA

O catálogo e o schema utilizados pelo projeto devem estar disponíveis e com as permissões necessárias para leitura e gravação das tabelas Delta. No projeto, o catálogo é pi6, com o schema dados_ssp_zonas (tabelas analíticas) e o schema dados_ssp_zonas_restrito (correspondência dos pseudônimos), cujo acesso fica restrito às autoras.

8.3 EXECUÇÃO DOS NOTEBOOKS

A ordem de execução deve seguir o fluxo definido na documentação dos notebooks do Projeto Integrador 6. Os notebooks 00 e 01 podem ser executados em qualquer ordem entre si; a partir do 02, a ordem é sequencial (02 → 03 → 04 → 05). O 06 depende do 03 e prepara as tabelas do app; para publicar o app, o 05 também precisa ter rodado até a Célula 15.1.

Quadro 6 – Notebooks do pipeline

Etapa	Notebook / componente	Função
00	00_zoneamento_bairros	Cálculo algorítmico da correspondência bairro → zona e setor → zona
01	01_etl_pipeline	Extração, tratamento e organização dos dados de ocorrências da SSP-SP
02	02_populacao_normalizacao	Integração da população por zona via setores censitários
03	03_criacao_classes_historicas	Cálculo da taxa e definição das classes históricas por tercis (P33/P67)
04	04_analise_exploratoria	Análise exploratória e caracterização das zonas
05	05_modelagem_ml	Experimentos de classificação com Árvore de Decisão, Random Forest e XGBoost
06	06_tabelas_app	Contagens agregadas por zona para o app, sem registros individuais

Fonte: elaborado pelas autoras (2026).

8.4 CHAVE DE PSEUDONIMIZAÇÃO

Antes da primeira execução do 01, crie a chave de pseudonimização num secret scope. Sem ela, o 01 para antes de gravar qualquer dado. Use uma frase longa e aleatória, guardada fora do repositório. A chave precisa continuar a mesma entre execuções: se ela mudar, todos os pseudônimos mudam.

```
databricks secrets create-scope pi6
databricks secrets put-secret pi6 chave_pseudonimizacao
```

9 MLFLOW E REGISTRO DOS EXPERIMENTOS

O MLflow é utilizado para acompanhar os experimentos de aprendizado de máquina, registrados no experimento /pi6_classificacao_historica_zonas. Cada execução registra parâmetros, métricas e resultados, permitindo comparar as diferentes abordagens.

- Registrar as execuções dos modelos;
- Acompanhar métricas como acurácia, precisão, recall, F1-score e o p-valor do teste de permutação;
- Registrar configurações dos modelos e hiperparâmetros;
- Manter histórico dos experimentos;
- Facilitar a comparação e a rastreabilidade dos resultados.

Só o modelo com maior F1 macro na validação leave-one-out (excluída a referência) é registrado no Unity Catalog, como pi6.dados_ssp_zonas.PI6_ClassificadorPerfilHistoricoZona. As tags selecionado_para_registro, criterio_selecao e supera_baseline permitem conferir a escolha. Na execução final (15/10/2026), o selecionado foi o XGBoost, com F1 macro de 0,23 e p-valor de 0,66 em 680 permutações, ou seja, sem diferença significativa em relação ao acaso.

O app não executa o modelo: ele mostra os resultados que o 05 grava nas tabelas modelo_*.

10 DEPLOY DO DATABRICKS APP

A interface é um app Streamlit publicado no Databricks Apps com o nome pi6-zonas. O código fica na pasta app/ do repositório. O app lê apenas tabelas agregadas por zona, por meio de um SQL Warehouse, e nunca acessa a base de ocorrências nem o schema restrito.

10.1 ESTRUTURA DO APP

Quadro 7 – Arquivos do Databricks App

Arquivo	Função
app.py	Ponto de entrada e navegação entre as quatro páginas
app.yaml	Comando de inicialização e variáveis de ambiente (warehouse e schema)
dados.py	Leitura das tabelas do Unity Catalog via SQL Warehouse, com cache
componentes.py	Elementos visuais e formatação compartilhados
paginas/	Páginas O projeto, Painel por região, Teste com IA e Como fizemos e LGPD
requirements.txt	Bibliotecas Python do app
.streamlit/config.toml	Tema visual do Streamlit

Fonte: elaborado pelas autoras (2026).

10.2 PREPARAR AS TABELAS

Execute o 05 até a Célula 15.1, que grava as tabelas modelo_*, e o 06, que grava painel_ocorrencias_agregadas. Sem essas tabelas, as páginas do app mostram um aviso no lugar dos resultados.

10.3 CRIAR O APP

1. Em Compute → Apps, selecione Create app → Custom e dê o nome pi6-zonas.

2. Na seção Resources, adicione um SQL warehouse com a chave sql-warehouse e a permissão Can use. O Databricks injeta o ID dele na variável DATABRICKS_WAREHOUSE_ID, declarada no app.yaml.

3. Conclua a criação. O Databricks cria uma identidade de serviço (service principal) própria do app, mostrada na aba Authorization.

10.4 ENVIAR O CÓDIGO E PUBLICAR

Com a Databricks CLI configurada para o workspace do projeto, sincronize a pasta app/ com o workspace e publique o app:

```
databricks sync app/ /Workspace/Users/cdnfatecvotorantim@gmail.com/pi6-zonas
databricks apps deploy pi6-zonas \
  --source-code-path /Workspace/Users/cdnfatecvotorantim@gmail.com/pi6-zonas
```

O botão Deploy, na página do app, faz o mesmo pela interface. A cada alteração no código, repita os dois comandos.

10.5 PERMISSÕES DO APP

Dê ao service principal do app permissão de leitura apenas nas tabelas agregadas. Os comandos estão no início do 06_tabelas_app.py; substitua <sp> pelo ID mostrado na aba Authorization:

```
GRANT USE CATALOG ON CATALOG pi6 TO `<sp>`;
GRANT USE SCHEMA ON SCHEMA pi6.dados_ssp_zonas TO `<sp>`;
GRANT SELECT ON TABLE pi6.dados_ssp_zonas.painel_ocorrencias_agregadas TO `<sp>`;
GRANT SELECT ON TABLE pi6.dados_ssp_zonas.classes_historicas_zonas TO `<sp>`;
GRANT SELECT ON TABLE pi6.dados_ssp_zonas.populacao_zonas TO `<sp>`;
GRANT SELECT ON TABLE pi6.dados_ssp_zonas.modelo_resultados TO `<sp>`;
GRANT SELECT ON TABLE pi6.dados_ssp_zonas.modelo_previsoes_zonas TO `<sp>`;
GRANT SELECT ON TABLE pi6.dados_ssp_zonas.modelo_permutacoes TO `<sp>`;
GRANT SELECT ON TABLE pi6.dados_ssp_zonas.modelo_importancias TO `<sp>`;
```

O app não recebe nenhuma permissão em ocorrencias_ddm nem no schema dados_ssp_zonas_restrito.

10.6 INICIAR, ACESSAR E PARAR

O app só consome recursos enquanto está ligado. Inicie-o antes do uso e pare-o depois, pela página do app ou pela CLI:

```
databricks apps start pi6-zonas
databricks apps stop pi6-zonas
```

Endereço: https://pi6-zonas-7474645265501383.aws.databricksapps.com. O acesso exige login com uma conta do workspace do projeto.

10.7 EXECUTAR LOCALMENTE (DESENVOLVIMENTO)

Para testar alterações antes do deploy, com o acesso ao workspace configurado no ~/.databrickscfg:

```
cd app
python -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt
DATABRICKS_WAREHOUSE_ID=<id-do-warehouse> streamlit run app.py
```

11 TESTES DE DEPLOY

Testes realizados em 17/10/2026, com o app publicado no workspace do projeto.

Quadro 8 – Testes de deploy

Teste	Procedimento	Resultado esperado	Status
Acesso	Abrir a URL do app com uma conta do workspace	Interface carregada	OK (17/10/2026)
Consulta territorial	Selecionar município e zona no Painel por região	Resultados apresentados	Município OK; zona OK (17/10/2026)
Taxa	Consultar as zonas com dados disponíveis	Taxa histórica exibida	OK (17/10/2026)
Classificação	Consultar a classe histórica	Baixo/Médio/Alto exibido corretamente	OK (17/10/2026)
Interface	Navegar pelas quatro páginas	Sem erros de interface	OK (17/10/2026)
Modelo	Comparar a página Teste com IA com o MLflow	Mesmas métricas (F1 0,23; p = 0,66; 680 permutações)	OK (17/10/2026)
Proteção de dados	Conferir as permissões do service principal no Unity Catalog	Só SELECT nas tabelas agregadas; sem acesso a ocorrencias_ddm e ao schema restrito	OK (17/10/2026)

Fonte: elaborado pelas autoras (2026).

12 ATUALIZAÇÃO DA SOLUÇÃO

Atualizações dos dados ou da modelagem devem preservar a rastreabilidade das alterações. Antes de atualizar a interface, recomenda-se executar novamente os processos necessários, verificar as tabelas resultantes e validar os experimentos do MLflow.

- Atualizar ou processar a fonte de dados;
- Executar as etapas de tratamento e integração necessárias;
- Validar as tabelas Delta resultantes;
- Recalcular os indicadores e a classificação histórica quando a base for atualizada;
- Executar e registrar os experimentos de modelagem necessários;
- Rodar o 06, abrir o app e usar o botão Recarregar dados (o app guarda os dados em cache por até 1 hora);
- Se o código do app mudou, repetir o envio e o deploy (seção 10.4);
- Atualizar este documento com a nova versão do deploy.

13 SEGURANÇA E BOAS PRÁTICAS

- Não registrar senhas, tokens ou chaves de acesso nos notebooks ou neste documento;
- Utilizar os mecanismos de autenticação e permissões disponíveis no ambiente Databricks;
- Manter dados e modelos organizados no Unity Catalog;
- Evitar acesso público não autorizado aos ativos do projeto;
- Manter a chave de pseudonimização apenas no secret scope pi6;
- Dar ao service principal do app apenas SELECT nas tabelas agregadas;
- Manter o app parado quando não estiver em uso; o acesso exige login no workspace;
- Registrar alterações relevantes na versão do documento e da solução.

14 MONITORAMENTO

O monitoramento deve considerar tanto a disponibilidade da interface quanto a consistência dos dados e dos modelos. O MLflow fornece rastreabilidade dos experimentos, enquanto as tabelas Delta e o Unity Catalog organizam os dados utilizados pela solução.

Quadro 9 – Aspectos monitorados

Aspecto	Acompanhamento
Interface	Estado do app em Compute → Apps (Running ou Stopped) e aba Logs do app
Dados	Existência e consistência das tabelas Delta
Modelos	Experimentos, parâmetros e métricas registrados no MLflow
Classificação	Verificação dos pontos de corte e das classes geradas após atualizações

Fonte: elaborado pelas autoras (2026).

15 RESPONSÁVEIS

Quadro 10 – Responsáveis pela solução

Responsável	Atividade
Débora Kocks Nogueira	Desenvolvimento, documentação e validação da solução
Stefanie Mayumi Inacio Kobayashi	Desenvolvimento, documentação e validação da solução

Fonte: elaborado pelas autoras (2026).