**Centro Paula Souza**
**Faculdade de Tecnologia de Votorantim**
Curso Superior de Tecnologia em Ciência de Dados para Negócios

DÉBORA KOCKS NOGUEIRA
STEFANIE MAYUMI INACIO KOBAYASHI

# CLASSIFICAÇÃO HISTÓRICA DE OCORRÊNCIAS DE VIOLÊNCIA CONTRA A MULHER EM SOROCABA E VOTORANTIM

GUIA DE USO

**VOTORANTIM**
2026

# SUMÁRIO


**1 OBJETIVO** **3**

**2 VISÃO GERAL DA SOLUÇÃO** **3**

**3 ACESSO À SOLUÇÃO** **4**

3.1 ABRIR O APP 4
3.2 NAVEGAÇÃO 4

**4 UTILIZANDO A INTERFACE** **5**

4.1 PÁGINA O PROJETO 5
4.2 PÁGINA PAINEL POR REGIÃO 5
4.3 CONSULTANDO OS RESULTADOS 6
4.4 PÁGINA TESTE COM IA 6
4.5 PÁGINA COMO FIZEMOS E LGPD 7

**5 INTERPRETANDO OS RESULTADOS** **8**

5.1 TAXA HISTÓRICA POR 10.000 HABITANTES 8
5.2 CLASSIFICAÇÃO HISTÓRICA (BAIXO, MÉDIO E ALTO) 8
5.3 INDICADORES POPULACIONAIS E SOCIOECONÔMICOS 8
5.4 RESULTADO DO APRENDIZADO DE MÁQUINA 9

**6 LIMITAÇÕES IMPORTANTES** **10**

**7 GLOSSÁRIO** **10**

## 1 OBJETIVO

Este Guia de Uso descreve, de forma prática e detalhada, como utilizar e interpretar os resultados da solução desenvolvida no Projeto Integrador 6 (PI6) da FATEC Votorantim.

A solução dá continuidade aos projetos integradores anteriores e amplia a análise de dados de violência contra a mulher, utilizando dados públicos da SSP-SP, do Censo 2022 do IBGE, do Índice Paulista de Vulnerabilidade Social (IPVS) da Fundação SEADE e dados geográficos do OpenStreetMap, organizados em ambiente Databricks.

Os resultados são consultados em um Databricks App, com acesso restrito às pessoas autorizadas no workspace do projeto:
https://pi6-zonas-7474645265501383.aws.databricksapps.com

## 2 VISÃO GERAL DA SOLUÇÃO

Quadro 1 – Componentes da solução

| Componente | Tecnologia | Função |
|---|---|---|
| Processamento | Databricks | Execução dos notebooks e processamento dos dados |
| Armazenamento | Delta Lake | Armazenamento estruturado das informações |
| Governança | Unity Catalog | Organização e governança dos dados e ativos |
| Análise | Python / Pandas / Spark | Tratamento, agregação e análise dos dados |
| Modelagem | Árvore de Decisão, Random Forest e XGBoost | Classificação dos perfis históricos |
| Experimentos | MLflow | Registro de parâmetros, métricas e resultados |
| Interface | Databricks Apps (Streamlit) | Consulta e visualização dos resultados |

Fonte: elaborado pelas autoras (2026).

A unidade territorial utilizada na análise é composta pelas zonas Norte, Sul, Leste, Oeste e Centro de Sorocaba e de Votorantim. Como não existe divisão oficial em zonas, elas foram traçadas por uma regra única: o que está a até 1.500 m do centro do município é Centro; o restante é dividido pela direção em relação ao

centro, em quadrantes de 90°. A regra é aplicada aos bairros do OpenStreetMap e aos setores censitários do IBGE.

## 3 ACESSO À SOLUÇÃO

### 3.1 ABRIR O APP

1. Abra o endereço https://pi6-zonas-7474645265501383.aws.databricksapps.com no navegador.

2. Entre com a sua conta do workspace Databricks do projeto. Quem não tem acesso ao workspace não consegue abrir o app; nesse caso, peça acesso às responsáveis.

3. Se aparecer a mensagem de que o app não está disponível, ele está parado para economizar recursos. Peça às responsáveis que o iniciem (Deploy Guide, seção 10.6).

### 3.2 NAVEGAÇÃO

O menu lateral dá acesso às quatro páginas do app:

Quadro 2 – Páginas do app

| Página | Conteúdo |
|---|---|
| O projeto | Resumo do projeto: números gerais, resultado por região e resultado do teste com IA |
| Painel por região | Consulta de uma cidade e de uma região, com taxa, grupo e perfil dos casos |
| Teste com IA | Comparação dos modelos, teste de sorte (permutação) e acertos por região |
| Como fizemos e LGPD | Método, proteção de dados, limites do estudo e glossário |

Fonte: elaborado pelas autoras (2026).

Abaixo das páginas, o menu mostra as autoras e o botão Recarregar dados, que lê de novo as tabelas do Databricks. Use-o depois de uma nova execução dos notebooks.

# 4 UTILIZANDO A INTERFACE

## 4.1 PÁGINA O PROJETO

A página inicial resume o projeto. No topo, quatro indicadores: boletins analisados (2.392, os que puderam ser ligados a uma região), moradores nas regiões (851.605), regiões comparadas (9 de 10) e anos estudados (2023 a 2026).

Em seguida, a página explica por que a análise é feita por região, mostra o grupo de cada região num esquema por cidade (Figura 1) e resume o teste com inteligência artificial. No fim, apresenta as etapas de tratamento dos dados e um glossário.

Figura 1 – Página O projeto




Fonte: elaborado pelas autoras (2026).

## 4.2 PÁGINA PAINEL POR REGIÃO

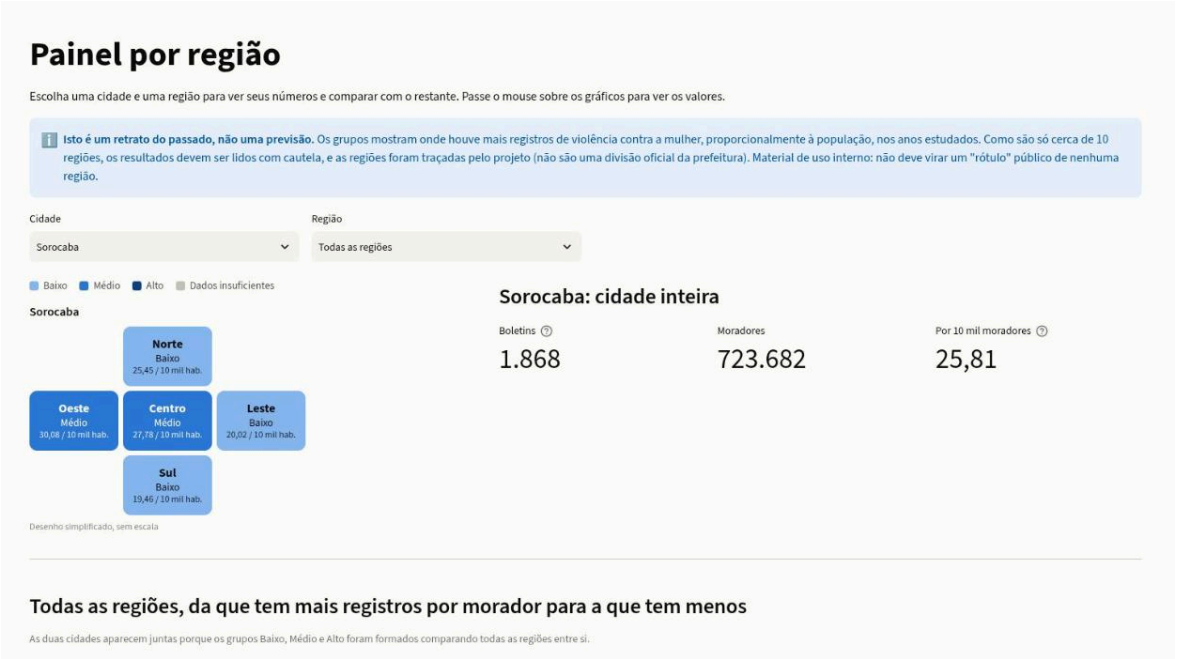
No Painel por região, escolha a cidade e a região nos dois campos do topo da página:

Quadro 3 – Filtros do Painel por região

| Campo | Opções / conteúdo | Finalidade |
|---|---|---|
| Cidade | Sorocaba ou Votorantim | Selecionar o município de interesse |
| Região | Todas as regiões, Norte, Sul, Leste, Oeste ou Centro | Selecionar a unidade territorial analisada |

Fonte: elaborado pelas autoras (2026).

Figura 2 – Página Painel por região




Fonte: elaborado pelas autoras (2026).

## 4.3 CONSULTANDO OS RESULTADOS

Com uma região selecionada, o painel mostra:

- Grupo: a classe histórica da região (Baixo, Médio ou Alto), ou Dados insuficientes;
- Boletins, moradores e registros por 10 mil moradores;
- Quem mora na região: idade média, pessoas por casa, casas chefiadas por mulheres e moradores em áreas vulneráveis (IBGE e Fundação SEADE);
- A posição da região num gráfico com todas as regiões, da maior para a menor taxa;
- Como são os casos registrados: a divisão dos boletins por período do dia, dia da semana, local, mês do fato, ano do registro ou tipo de crime, comparando a região escolhida com o conjunto.

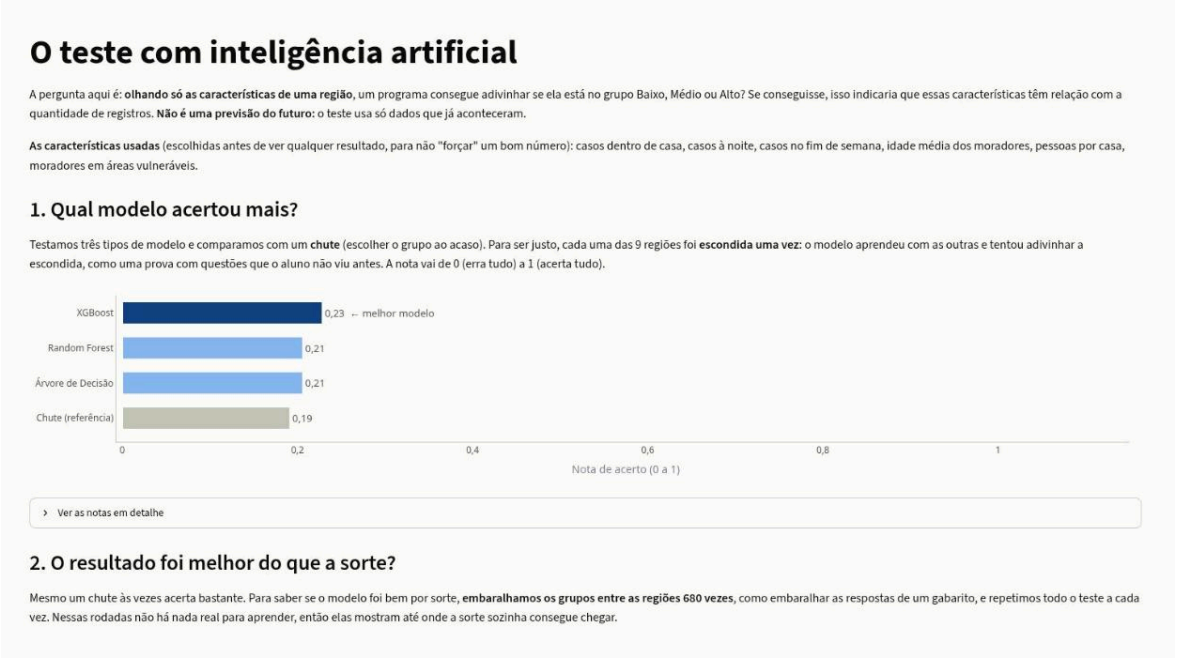
Com a opção Todas as regiões, os indicadores do topo passam a ser os totais da cidade inteira. Passe o mouse sobre os gráficos para ver os valores.

## 4.4 PÁGINA TESTE COM IA

Mostra se as características das regiões ajudam a explicar o grupo de cada uma, em quatro partes: a nota de cada modelo comparada com um chute, o teste de

sorte com os grupos embaralhados, o que o modelo disse sobre cada região e as características em que o modelo mais se apoiou (Figura 3). A interpretação está na seção 5.4.

Figura 3 – Página Teste com IA

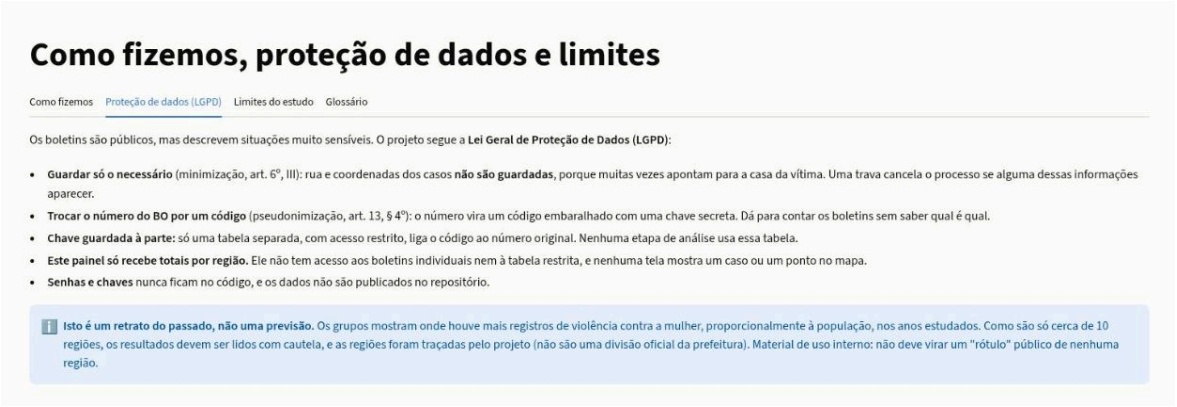



Fonte: elaborado pelas autoras (2026).

## 4.5 PÁGINA COMO FIZEMOS E LGPD

Reúne, em quatro abas, o método (Como fizemos), as medidas de proteção de dados (Proteção de dados – LGPD), os limites do estudo e o glossário (Figura 4).

Figura 4 – Página Como fizemos e LGPD, aba Proteção de dados




Fonte: elaborado pelas autoras (2026).

# 5 INTERPRETANDO OS RESULTADOS

## 5.1 TAXA HISTÓRICA POR 10.000 HABITANTES

A taxa é calculada pela expressão:

**Taxa = (ocorrências da zona ÷ população da zona) × 10.000**

A utilização da população como referência permite comparar zonas com diferentes tamanhos populacionais. Dessa forma, a análise não se limita à quantidade absoluta de registros.

## 5.2 CLASSIFICAÇÃO HISTÓRICA (BAIXO, MÉDIO E ALTO)

Quadro 4 – Interpretação das classes históricas

| Categoria | Interpretação |
|---|---|
| Baixo | Zona posicionada no primeiro tercil da distribuição das taxas históricas |
| Médio | Zona posicionada no segundo tercil da distribuição das taxas históricas |
| Alto | Zona posicionada no terceiro tercil da distribuição das taxas históricas |

Fonte: elaborado pelas autoras (2026).

As categorias representam posições relativas dentro da distribuição histórica das taxas observadas. Elas não correspondem a uma previsão de acontecimentos futuros.

No conjunto de resultados analisado, os pontos de corte foram P33 = 27,00 e P67 = 33,78 registros por 10.000 habitantes. Esses valores são específicos da distribuição analisada e podem ser recalculados quando a base for atualizada. Uma zona com menos de 5 ocorrências no período não recebe classe e aparece como Dados insuficientes; no período analisado, foi o caso da zona Norte de Votorantim.

## 5.3 INDICADORES POPULACIONAIS E SOCIOECONÔMICOS

- Idade média;
- Taxa de alfabetização;
- Percentual de domicílios com chefia feminina;

- Número médio de moradores por domicílio.
- Percentual da população em setores de vulnerabilidade alta (IPVS 2022, Fundação SEADE).

Essas informações caracterizam as zonas de forma descritiva. Idade média, moradores por domicílio e vulnerabilidade alta também entram no teste com IA; alfabetização e chefia feminina são apenas descritivas.

## 5.4 RESULTADO DO APRENDIZADO DE MÁQUINA

A classificação histórica Baixo, Médio ou Alto é definida antes da aplicação dos modelos. O aprendizado de máquina utiliza essa classificação como variável-alvo e procura classificar os perfis históricos das zonas a partir das características observadas nos dados.

Quadro 5 – Resultados dos modelos na execução final

| **Modelo** | **Resultado na execução final (15/10/2026)** |
|---|---|
| Referência (chute) | F1 macro 0,19 (média de 200 sorteios) |
| Árvore de Decisão | F1 macro 0,21; acertou 2 de 9 zonas |
| Random Forest | F1 macro 0,21; acertou 2 de 9 zonas |
| XGBoost | F1 macro 0,23; acertou 2 de 9 zonas (selecionado e registrado) |

Fonte: elaborado pelas autoras (2026).

Os experimentos são acompanhados pelo MLflow. Cada zona é classificada por um modelo treinado sem ela (leave-one-out). O XGBoost usa parâmetros fixos: uma busca de hiperparâmetros honesta exigiria validação aninhada, inviável com nove zonas.

Como ler: no teste de permutação, os grupos foram embaralhados entre as zonas 680 vezes. Em 66% dessas rodadas (p = 0,66), um modelo sem nenhuma relação real chegou a um F1 igual ou maior. Portanto, o resultado não se distingue do acaso: com nove zonas, não é possível concluir que as características expliquem o grupo. O resultado principal do projeto é a classificação por taxa, que não depende de modelo.

A confiança do modelo em cada resposta e o peso de cada característica, mostrados no app, não indicam a chance de violência numa região nem causas.

## 6 LIMITAÇÕES IMPORTANTES

- A solução utiliza dados históricos disponíveis nas fontes públicas utilizadas no projeto.
- A classificação Baixo, Médio e Alto não representa previsão de acontecimentos futuros.
- A análise considera até dez zonas territoriais entre os dois municípios.
- Os pontos de corte dos tercis dependem da distribuição observada na base utilizada.
- A divisão em zonas é uma construção algorítmica para fins de análise e não corresponde necessariamente a uma divisão administrativa oficial.
- Existem registros com informações ausentes ou sem zona atribuída.
- Os resultados socioeconômicos e suas correlações devem ser interpretados de forma descritiva, considerando o número reduzido de unidades territoriais.
- As taxas são de registro: refletem também o acesso à delegacia e a disposição para registrar (subnotificação).
- O app mostra a última execução dos notebooks; depois de uma nova execução, use o botão Recarregar dados.
- A classificação é material de uso interno e não deve ser divulgada como rótulo público das regiões.

## 7 GLOSSÁRIO

Quadro 6 – Glossário

| Termo | Definição |
|---|---|
| Zona territorial | Unidade de análise organizada nas categorias Norte, Sul, Leste, Oeste e Centro. |
| Taxa por 10.000 habitantes | Relação entre ocorrências e população da zona, multiplicada por 10.000. |
| Classificação histórica | Classificação Baixo, Médio ou Alto definida pela distribuição histórica das taxas. |
| Tercil | Divisão da distribuição em três grupos de posições relativas. |
| Delta Lake | Tecnologia utilizada para armazenamento estruturado dos dados no Databricks. |
| Unity Catalog | Recurso utilizado para organização e governança dos ativos de dados e modelos. |
| Pipeline ETL | Extração, Transformação e Carga, processo automatizado de coleta, tratamento e armazenamento dos dados |

| | |
|---|---|
| MLflow | Ferramenta utilizada para acompanhamento e registro dos experimentos de aprendizado de máquina. |
| Databricks | Ambiente utilizado para processamento, armazenamento, análise e modelagem. |
| SSP-SP | Secretaria da Segurança Pública do Estado de São Paulo. |
| IBGE | Instituto Brasileiro de Geografia e Estatística. |
| OpenStreetMap | Fonte de informações geográficas utilizada na estruturação territorial. |
| DDM | Delegacia de Defesa da Mulher. |
| Databricks App | Aplicação web publicada dentro do workspace Databricks; neste projeto, a interface em Streamlit. |
| IPVS | Índice Paulista de Vulnerabilidade Social, da Fundação SEADE. |
| F1 macro | Nota de acerto de 0 a 1 que dá o mesmo peso às três classes. |
| Leave-one-out | Avaliação em que cada zona é classificada por um modelo treinado com todas as outras. |
| Teste de permutação e p-valor | Repetição do teste com os grupos embaralhados; o p-valor é a fração de rodadas em que o acaso empatou ou superou o resultado real. |

Fonte: elaborado pelas autoras (2026).