CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA “PAULA SOUZA”
FACULDADE DE TECNOLOGIA DE VOTORANTIM BENEDICTO PAGLIATO
CURSO SUPERIOR DE TECNOLOGIA EM
CIÊNCIA DE DADOS PARA NEGÓCIOS

PROJETO INTEGRADOR VI: CLASSIFICAÇÃO HISTÓRICA DE OCORRÊNCIAS DE VIOLÊNCIA CONTRA A MULHER EM SOROCABA E VOTORANTIM

DÉBORA KOCKS NOGUEIRA
STEFANIE MAYUMI INACIO KOBAYASHI RESENDE

VOTORANTIM – SP
2026

CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA “PAULA SOUZA”
FACULDADE DE TECNOLOGIA DE VOTORANTIM BENEDICTO PAGLIATO
CURSO SUPERIOR DE TECNOLOGIA EM
CIÊNCIA DE DADOS PARA NEGÓCIOS

PROJETO INTEGRADOR VI: CLASSIFICAÇÃO HISTÓRICA DE OCORRÊNCIAS DE VIOLÊNCIA CONTRA A MULHER EM SOROCABA E VOTORANTIM

DÉBORA KOCKS NOGUEIRA
STEFANIE MAYUMI INACIO KOBAYASHI RESENDE

Trabalho desenvolvido e apresentado como requisito para a conclusão do Curso Superior de Tecnologia em Ciência de Dados para Negócios, contemplando o Relatório Técnico elaborado no âmbito do Projeto Integrador VI da Faculdade de Tecnologia de Votorantim.
Orientador(a): Prof. Luis Claudio dos Santos

VOTORANTIM - SP
2026

FOLHA DE APROVAÇÃO

Nome: Débora Kocks Nogueira, Stefanie Mayumi Inacio Kobayashi Resende
Título: Classificação Histórica de Ocorrências de Violência Contra a Mulher em Sorocaba e Votorantim
Aprovado em: ___/____/_____

Banca:

Nome:
_____.
Instituição:
_____.
Nome:
_____.
Instituição:
_____.
Nome:
_____.
Instituição:
_____.

RESUMO

Este trabalho documenta o Projeto Integrador VI do Curso Superior de Tecnologia em Ciência de Dados para Negócios da Fatec Votorantim, que desenvolveu uma solução analítica reproduzível para caracterizar a distribuição histórica dos registros de violência contra a mulher feitos pelas Delegacias de Defesa da Mulher (DDM) de Sorocaba e Votorantim (SP). A solução foi implementada no Databricks como um pipeline de sete notebooks que integra os registros públicos da Secretaria da Segurança Pública do Estado de São Paulo (SSP-SP), os dados por setor censitário do Censo 2022 do Instituto Brasileiro de Geografia e Estatística (IBGE), o Índice Paulista de Vulnerabilidade Social (IPVS) e dados geográficos do OpenStreetMap, com armazenamento em Delta Lake, governança no Unity Catalog, registro dos experimentos no MLflow e consulta dos resultados agregados em um aplicativo publicado no próprio Databricks. Os territórios foram organizados em zonas calculadas por ângulo e distância até o centro de cada município, e a correspondência entre os bairros dos boletins e as zonas foi verificada manualmente, o que reduziu os registros sem zona de 16,4% para 4,8% da base. A base reúne 2.513 registros de boletins registrados entre 2023 e agosto de 2026. A normalização pela população mostrou que, embora Sorocaba concentre o maior número absoluto de registros, as quatro maiores taxas estão em Votorantim, com destaque para a zona Centro (55,47 registros por 10.000 habitantes). As zonas foram classificadas como Baixo, Médio ou Alto pelos tercis da taxa. A seguir, Árvore de Decisão, Random Forest e XGBoost foram avaliados, de forma experimental, por validação cruzada leave-one-out e teste de permutação. O melhor classificador acertou 2 das 9 zonas (F1-score macro de 0,23) e não se distinguiu do acaso ($p = 0,68$); a inclusão da vulnerabilidade social do IPVS não alterou as previsões ($p = 0,66$ na execução final). Conclui-se que a classificação histórica normalizada é um insumo interno útil para a análise territorial, sem caráter preditivo, e que o número reduzido de zonas não sustenta um classificador. O tratamento dos dados adotou minimização, pseudonimização e agregação territorial, em conformidade com a Lei Geral de Proteção de Dados Pessoais.

Palavras-chave: violência contra a mulher; classificação histórica; normalização populacional; proteção de dados; validação cruzada.

ABSTRACT

This work documents the sixth Integrative Project of the Data Science for Business Technology Program at Fatec Votorantim, which developed a reproducible analytical solution to characterize the historical distribution of reports of violence against women filed at the Women's Police Stations (DDM) of Sorocaba and Votorantim, São Paulo, Brazil. The solution was implemented in Databricks as a pipeline of seven notebooks that integrates public records from the São Paulo State Public Security Department (SSP-SP), census-tract data from the 2022 Census of the Brazilian Institute of Geography and Statistics (IBGE), the São Paulo Social Vulnerability Index (IPVS) and geographic data from OpenStreetMap, with Delta Lake storage, Unity Catalog governance, MLflow experiment tracking and an application published in Databricks to consult the aggregated results. The territories were organized into zones computed from the angle and distance to each municipality's center, and the matching between the neighborhoods in the reports and the zones was manually verified, which reduced the share of records without a zone from 16.4% to 4.8%. The dataset contains 2,513 records of reports filed between 2023 and August 2026. Population normalization showed that, although Sorocaba concentrates the largest absolute number of records, the four highest rates are in Votorantim, especially its Centro zone (55.47 records per 10,000 inhabitants). The zones were classified as Low, Medium or High by the rate tertiles. Decision Tree, Random Forest and XGBoost were then evaluated, as an experiment, with leave-one-out cross-validation and a permutation test. The best classifier correctly classified 2 of the 9 zones (macro F1-score of 0.23) and could not be distinguished from chance ($p = 0.68$); adding the IPVS social vulnerability variable did not change the predictions ($p = 0.66$ in the final run). The study concludes that the normalized historical classification is a useful internal input for territorial analysis, without predictive meaning, and that the small number of zones does not support a classifier. Data processing adopted minimization, pseudonymization and territorial aggregation, in line with the Brazilian General Data Protection Law.

Keywords: violence against women; historical classification; population normalization; data protection; cross-validation.

LISTA DE ILUSTRAÇÕES

Figura 1 – Registros por ano de registro e por mês do fato.....30
Figura 2 – Principais locais e naturezas das ocorrências.....31
Figura 3 – Indicadores socioeconômicos e taxa de registros por zona.....32
Figura 4 – Ordenação das zonas pela contagem absoluta e pela taxa por 10.000 habitantes.....34
Figura 5 – Classe histórica por zona (diagrama esquemático).....34
Figura 6 – Teste de permutação: F1-score real e F1-score com as classes embaralhadas.....35
Figura 7 – Página Painel por região do aplicativo pi6-zonas.....39

LISTA DE TABELAS

Tabela 1 – Principais mudanças do PI5 para o PI6.....11
Tabela 2 – Ferramentas utilizadas no desenvolvimento.....18
Tabela 3 – Etapas do pipeline e tabelas produzidas.....18
Tabela 4 – Bairros do OpenStreetMap e setores censitários por zona.....20
Tabela 5 – Verificação manual das correspondências por nome parecido.....21
Tabela 6 – Como cada bairro da SSP-SP recebeu a sua zona.....22
Tabela 7 – Plano de testes da disponibilização.....27
Tabela 8 – Campos da SSP-SP: mantidos, transformados e removidos.....28
Tabela 9 – Registros por ano de registro e ano do fato.....30
Tabela 10 – Registros, população, taxa e classe histórica por zona (registros de 2023 a agosto de 2026).....33
Tabela 11 – Desempenho dos classificadores (validação leave-one-out, 9 zonas, protocolos v3 e v4).....35
Tabela 12 – Histórico das execuções da modelagem.....36
Tabela 13 – Orientações jurídicas e medidas adotadas.....37
Tabela 14 – Resultado do plano de testes.....38

LISTA DE ABREVIATURAS E SIGLAS

API Application Programming Interface (Interface de Programação de Aplicações)

BO Boletim de Ocorrência

DDM Delegacia de Defesa da Mulher

EPSG European Petroleum Survey Group (código de sistema de referência)

ETL Extract, Transform, Load (Extração, Transformação e Carga)

Fatec Faculdade de Tecnologia

HMAC Hash-based Message Authentication Code (código de autenticação baseado em hash)

IBGE Instituto Brasileiro de Geografia e Estatística

IPVS Índice Paulista de Vulnerabilidade Social

LGPD Lei Geral de Proteção de Dados Pessoais

OPAS Organização Pan-Americana da Saúde

OSM OpenStreetMap

PI Projeto Integrador

SEADE Fundação Sistema Estadual de Análise de Dados

SIRGAS Sistema de Referência Geocêntrico para as Américas

SSP-SP Secretaria da Segurança Pública do Estado de São Paulo

UTM Universal Transversa de Mercator

SUMÁRIO

1 INTRODUÇÃO....10

1.1 Apresentação da organização....10
1.2 Estágio ao final do PI5 e evolução para o PI6....11
1.3 Objetivo geral....12
1.4 Objetivos específicos....12

2 REFERENCIAL TEÓRICO....13

2.1 Violência contra a mulher e dados públicos de segurança....13
2.2 Normalização populacional e classificação relativa de territórios....14
2.3 Arquitetura de dados e reprodutibilidade....14
2.4 Aprendizado de máquina para classificação....15
2.5 LGPD e proteção de dados....16

3 MATERIAIS E MÉTODOS....17

3.1 Fontes de dados e período de estudo....17
3.2 Ferramentas e processo de desenvolvimento....18
3.3 Arquitetura e organização do pipeline....18
3.4 Construção do zoneamento territorial....19
3.5 Correspondência entre os bairros dos boletins e as zonas....21
3.6 Indicadores populacionais e socioeconômicos....22
3.7 Classificação histórica das zonas....24
3.8 Modelagem....24
3.9 Procedimentos de verificação....26
3.10 Disponibilização dos resultados....26
3.11 Proteção e governança dos dados....28
3.12 Retenção e descarte dos dados....29

4 RESULTADOS E DISCUSSÃO....30

4.1 Análise exploratória dos dados....30
4.2 Classificação histórica das zonas....33
4.3 Desempenho dos modelos de classificação....35
4.4 Validação com as partes interessadas....37
4.5 Resultados dos testes, falhas e correções....38
4.6 Limitações....40

5 CONCLUSÃO....41

REFERÊNCIAS....43

APÊNDICE A – REGISTRO DE CONTATO COM A PROFA. EVELYN PRISCILA SANTINON SOLA (14/09/2026)....46

1 INTRODUÇÃO

A violência contra a mulher é um problema social, de saúde pública e de segurança que exige respostas baseadas em evidências. Os registros administrativos da segurança pública permitem observar parte desse fenômeno, mas não a sua totalidade, porque dependem de que os casos sejam comunicados e registrados.

Este relatório documenta o Projeto Integrador VI (PI6), que dá continuidade aos projetos anteriores do grupo com dados públicos de Sorocaba e Votorantim. O objetivo é organizar os registros por território, relacioná-los à população e a características socioeconômicas e produzir uma visão comparável entre as áreas, deixando claro que a classificação produzida é histórica e não uma previsão de novos casos.

1.1 Apresentação da organização

A Delegacia de Defesa da Mulher (DDM) de Sorocaba integra a Polícia Civil do Estado de São Paulo e realiza o atendimento especializado e o registro de ocorrências de violência contra a mulher. O projeto foi desenvolvido tendo a DDM de Sorocaba como organização parceira e considera como área de estudo os municípios de Sorocaba e Votorantim, que possui a sua própria DDM. Por isso, os registros analisados são das duas delegacias.

A parceria vem de semestres anteriores. No Projeto Integrador IV, o grupo desenvolveu um painel público com dados da SSP-SP sobre o tema. No Projeto Integrador V, o grupo se reuniu com a Delegada Renata Zanin, da DDM de Sorocaba, em 05/03/2026 (presencialmente) e em 18/03/2026 (por videoconferência), para apresentar a continuidade do projeto e discutir a sua viabilidade.

Os dados usados são públicos: os registros de ocorrências publicados pela Secretaria da Segurança Pública do Estado de São Paulo (SSP-SP), os dados do Censo Demográfico 2022 do Instituto Brasileiro de Geografia e Estatística (IBGE), o Índice Paulista de Vulnerabilidade Social (IPVS) da Fundação SEADE e dados geográficos do OpenStreetMap.

1.2 Estágio ao final do PI5 e evolução para o PI6

Ao final do PI5, o projeto tinha um pipeline de extração e tratamento dos dados da SSP-SP no Google Colab, armazenamento no Google BigQuery, um modelo XGBoost e uma interface em Streamlit hospedada em um servidor próprio do grupo. Duas limitações importantes foram identificadas. A primeira é a granularidade dos dados: eles não permitem acompanhar uma mesma vítima ou um mesmo agressor ao longo do tempo, o que não sustenta previsões de novos casos. A segunda é que métricas quase perfeitas obtidas naquela fase eram efeito de vazamento de rótulo, isto é, o modelo recebia informações usadas na própria construção da classe que deveria descobrir.

No PI6, a proposta foi reorganizada. A Tabela 1 resume as principais mudanças.

Tabela 1 – Principais mudanças do PI5 para o PI6

Aspecto	PI5	PI6
Infraestrutura	Google Colab e Google BigQuery	Databricks, Delta Lake e Unity Catalog
Enquadramento	Previsão de áreas de concentração	Classificação histórica e descritiva
Unidade territorial	Bairro	Zona calculada por ângulo e distância (bairro na primeira versão do PI6)
Correspondência de bairros	Automática, por nome parecido	Automática e verificada manualmente, com localização por coordenada
Modelagem	Um modelo (XGBoost), avaliado em uma divisão treino/teste	Três modelos comparados com um classificador de referência, validação leave-one-out e teste de permutação
Rastreabilidade	Sem registro de experimentos	MLflow e modelo registrado no Unity Catalog
Proteção de dados	Sem tratamento específico	Minimização de campos, pseudonimização do número do BO, orientação jurídica e plano de descarte
Interface	Aplicação em Streamlit hospedada em servidor próprio	Aplicativo publicado no Databricks (Databricks Apps), com login e leitura só de tabelas agregadas

Fonte: Elaborado pelas autoras (2026).

Durante o PI6, a unidade territorial também mudou. A primeira versão trabalhava com bairros, mas muitos bairros têm população pequena, o que gera taxas instáveis: poucas ocorrências a mais ou a menos mudam muito a taxa. Por sugestão do professor no acompanhamento técnico, a análise passou a usar zonas (Norte, Sul, Leste, Oeste e Centro), que reúnem vários bairros. Os experimentos das

duas versões continuam registrados no MLflow, o que permite comparar as abordagens.

Outra mudança do PI6 foi dar atenção específica à governança e à proteção dos dados. Embora os dados sejam públicos e não tragam o nome das vítimas, o grupo buscou orientação jurídica e incorporou medidas da Lei Geral de Proteção de Dados Pessoais (LGPD) ao próprio código, como a retirada de campos que não eram necessários e a pseudonimização do número do boletim.

1.3 Objetivo geral

Desenvolver, no ambiente Databricks, uma solução analítica reproduzível que integre, organize e analise dados públicos de ocorrências de violência contra a mulher em Sorocaba e Votorantim, organizando-os por zonas territoriais e usando indicadores populacionais, análise exploratória e técnicas de aprendizado de máquina para caracterizar e classificar o perfil histórico das zonas.

1.4 Objetivos específicos

a) caracterizar historicamente os registros de violência contra a mulher em Sorocaba e Votorantim, considerando a sua distribuição territorial e temporal;

b) integrar os registros da SSP-SP com dados populacionais e socioeconômicos do Censo 2022, do IPVS e do OpenStreetMap, permitindo comparar territórios com populações diferentes;

c) analisar, de forma descritiva, a relação entre as características das ocorrências, os indicadores socioeconômicos e a classificação histórica das zonas;

d) avaliar a aplicação de técnicas de aprendizado de máquina na classificação histórica das zonas, considerando as limitações do conjunto de dados e o número de zonas disponíveis;

e) assegurar que o tratamento e a divulgação dos dados estejam adequados aos princípios da LGPD.

2 REFERENCIAL TEÓRICO

Este capítulo apresenta os conceitos que fundamentam o projeto: a violência contra a mulher e os limites dos dados públicos; a normalização populacional e a classificação relativa de territórios; a arquitetura de dados; o aprendizado de máquina e as formas de avaliá-lo com poucos dados; e a proteção de dados pessoais.

2.1 Violência contra a mulher e dados públicos de segurança

A Lei nº 11.340/2006, conhecida como Lei Maria da Penha, cria mecanismos para coibir e prevenir a violência doméstica e familiar contra a mulher e reconhece as formas de violência física, psicológica, sexual, patrimonial e moral (BRASIL, 2006). A Organização Pan-Americana da Saúde caracteriza a violência contra as mulheres como um importante problema de saúde pública e de direitos humanos (OPAS, [2025]).

Estudos epidemiológicos usam registros administrativos para acompanhar o fenômeno. Lima *et al.* (2025), por exemplo, analisaram a tendência e o perfil das notificações de violência contra mulheres no Brasil entre 2014 e 2023. Esses registros, porém, não representam todos os casos: para entrar na base, a ocorrência precisa ser comunicada e registrada. Vasconcelos *et al.* (2024), comparando duas fontes de dados, mostraram que há grande subnotificação da violência contra as mulheres. Assim, a quantidade de registros em uma área indica os casos que chegaram à instituição, e não necessariamente todos os episódios ocorridos.

Essa característica é importante para análises territoriais. Diferenças entre áreas podem refletir não só diferenças na ocorrência do fenômeno, mas também diferenças no acesso aos serviços e na disposição para registrar. A SSP-SP publica dados de ocorrências com natureza, data, período, local e bairro (SÃO PAULO, [2025]), o que permite análises agregadas, mas com limitações como campos não preenchidos e grafias diferentes para o mesmo bairro. Por isso, este trabalho se concentra na distribuição histórica dos registros, sem inferências sobre indivíduos nem previsões.

2.2 Normalização populacional e classificação relativa de territórios

Comparar territórios pela contagem absoluta de registros favorece as áreas mais populosas: mais moradores tendem a gerar mais registros, sem que isso indique maior concentração relativa. Por isso, indicadores de saúde e de segurança usam taxas, que relacionam o número de eventos à população exposta em uma mesma base de referência, como 10.000 habitantes (BRASIL, 2008). Neste trabalho, a taxa de cada zona é o número de registros dividido pela população da zona, multiplicado por 10.000.

A partir das taxas, as zonas são agrupadas por tercis, isto é, pelos dois pontos que dividem as taxas ordenadas em três partes: o percentil 33 (P33) e o percentil 67 (P67). Zonas com taxa até o P33 ficam na classe Baixo; entre o P33 e o P67, Médio; acima do P67, Alto. Essa classificação é relativa: depende das demais zonas do conjunto e do período analisado. Uma zona Alto tem uma das maiores taxas deste conjunto, o que não significa uma condição permanente nem um limite absoluto do fenômeno.

Um cuidado adicional é que o resultado de uma análise por área depende de como as áreas são desenhadas. Esse efeito é conhecido como problema da unidade de área modificável: agrupar os mesmos dados em áreas diferentes pode mudar as taxas e as conclusões (OPENSHAW, 1984). Por isso, este relatório documenta a regra de formação das zonas e discute o seu efeito nos resultados.

2.3 Arquitetura de dados e reprodutibilidade

A arquitetura lakehouse combina a flexibilidade de um repositório de arquivos (data lake) com recursos de gerenciamento e confiabilidade de um data warehouse, usando formatos abertos (ARMBRUST *et al.*, 2021). O Delta Lake acrescenta ao armazenamento em arquivos transações confiáveis, controle de versão e controle de esquema (ARMBRUST *et al.*, 2020). No Databricks, o Unity Catalog organiza os dados em catálogo, esquema e tabela e permite definir quem pode acessar cada um (DATABRICKS, 2026). O MLflow registra os parâmetros, as métricas e os modelos de cada execução, permitindo comparar experimentos (ZAHARIA *et al.*, 2018; MLFLOW, 2026).

Neste trabalho, reprodutibilidade significa que o pipeline pode ser executado de novo com os mesmos dados, regras e configurações, chegando aos mesmos

resultados. Para isso, o código é versionado no GitHub, as decisões ficam documentadas nos notebooks, as tabelas intermediárias ficam no Delta Lake e cada execução da modelagem fica registrada no MLflow.

2.4 Aprendizado de máquina para classificação

Na classificação supervisionada, um modelo aprende a associar características de entrada a classes já conhecidas. A árvore de decisão faz perguntas sucessivas sobre as variáveis e produz regras fáceis de interpretar, mas pode mudar muito com pequenas alterações nos dados (BREIMAN *et al.*, 1984). O Random Forest combina muitas árvores treinadas em amostras diferentes e decide por votação, o que reduz essa instabilidade (BREIMAN, 2001). O XGBoost constrói árvores em sequência, cada uma corrigindo os erros das anteriores, com controles que limitam a complexidade (CHEN; GUESTRIN, 2016). Os modelos foram implementados com as bibliotecas scikit-learn (PEDREGOSA *et al.*, 2011) e XGBoost.

O desempenho é medido pela acurácia (proporção de acertos), pela precisão (das previsões de uma classe, quantas estavam certas), pelo recall (dos casos de uma classe, quantos foram encontrados) e pelo F1-score (média harmônica entre precisão e recall). Com três classes, usa-se a média macro, que dá o mesmo peso a cada classe (SOKOLOVA; LAPALME, 2009). Os resultados são comparados com um classificador de referência, que sorteia a classe sem olhar as variáveis: um modelo só tem valor se superar esse "chute".

Com bases muito pequenas, três cuidados são essenciais. O primeiro é evitar o vazamento de dados, que acontece quando o modelo recebe informações ligadas diretamente à resposta e produz métricas falsamente altas (KAUFMAN *et al.*, 2012). O segundo é a forma de avaliar: em vez de separar uma única vez uma parte para teste, a validação cruzada repete o treino e o teste em partes diferentes da base. No caso extremo, chamado *leave-one-out* ("deixe um de fora"), cada exemplo é testado uma vez por um modelo treinado com todos os outros, o que aproveita ao máximo uma base pequena (JAMES *et al.*, 2021). Se houver ajuste de parâmetros, ele precisa acontecer dentro de cada rodada, para a avaliação não ficar otimista (VARMA; SIMON, 2006). O terceiro é verificar se o resultado é melhor que o acaso: o teste de permutação embaralha as classes muitas vezes, repete a avaliação e

calcula com que frequência um modelo sem nenhuma relação real chega ao mesmo desempenho; essa frequência é o p-valor (OJALA; GARRIGA, 2010).

2.5 LGPD e proteção de dados

A Lei nº 13.709/2018, a LGPD, regula o tratamento de dados pessoais. Dado pessoal é a informação relacionada a uma pessoa natural identificada ou identificável, e dado pessoal sensível inclui, entre outros, dados sobre saúde e vida sexual (art. 5º, I e II). Tratamento é qualquer operação com dados pessoais, como coleta, armazenamento, uso e eliminação (art. 5º, X) (BRASIL, 2018).

Entre os princípios do art. 6º, quatro orientam diretamente este projeto: a finalidade (tratar os dados para propósitos legítimos e informados), a necessidade (limitar o tratamento ao mínimo necessário, o que na prática se chama minimização), a segurança (proteger os dados contra acessos não autorizados) e a prevenção (evitar danos). O fato de os dados estarem disponíveis ao público não dispensa esses cuidados: o tratamento de dados de acesso público deve considerar a finalidade, a boa-fé e o interesse público que justificaram a sua divulgação (art. 7º, §§ 3º e 4º) (BRASIL, 2018).

A lei também diferencia anonimização e pseudonimização. Na anonimização, o dado perde a possibilidade de associação a uma pessoa, considerando os meios técnicos razoáveis disponíveis (art. 5º, XI). Na pseudonimização, o dado só pode ser associado a uma pessoa com o uso de uma informação adicional mantida separadamente pelo controlador, em ambiente controlado e seguro (art. 13, § 4º) (BRASIL, 2018). A diferença é importante: um dado pseudonimizado continua sendo dado pessoal, porque a associação continua possível para quem tem acesso à informação adicional. A agregação territorial, por sua vez, reduz a exposição de registros individuais, mas não garante sozinha a anonimização, porque grupos com poucos registros ainda podem permitir a identificação.

3 MATERIAIS E MÉTODOS

Este capítulo descreve as fontes de dados, as ferramentas, o pipeline, a construção das zonas, a verificação da correspondência entre bairros e zonas, o cálculo dos indicadores, a classificação histórica, a modelagem, os procedimentos de verificação, a disponibilização dos resultados e as medidas de proteção de dados.

3.1 Fontes de dados e período de estudo

Os registros de ocorrências vêm das planilhas anuais SPDados Criminais da SSP-SP (SÃO PAULO, [2026]), filtradas para as DDMs de Sorocaba e Votorantim. As planilhas foram baixadas em 08/10/2026 e, a partir dessa data, a base foi congelada: o notebook de extração não foi executado novamente, para que todos os números deste relatório venham da mesma base. A população e os indicadores socioeconômicos vêm do Censo 2022 do IBGE, agregados por setor censitário (IBGE, [2026]), e do IPVS 2022 da Fundação SEADE, também por setor censitário (SEADE, 2025). Os bairros e o centro de cada cidade vêm do OpenStreetMap (OPENSTREETMAP CONTRIBUTORS, 2026), consultado pela API Overpass (OVERPASS API, 2026).

A base reúne **2.513 registros**, que correspondem a **2.445 boletins de ocorrência distintos**: um mesmo boletim pode aparecer em mais de uma linha quando registra mais de uma natureza de crime. A unidade de contagem deste trabalho é o registro (a linha da planilha), e a taxa de cada zona considera todos os registros.

A planilha traz duas informações de tempo diferentes. O **ano de registro** (ANO_ESTATISTICA) é o ano em que o boletim entrou na estatística da SSP-SP, e a **data do fato** é quando a ocorrência aconteceu. Como um fato pode ser comunicado anos depois, as datas de fato vão de julho de 2006 a agosto de 2026, embora todos os boletins tenham sido registrados entre 2023 e 2026. Por isso, o período de estudo é definido pelo ano de registro (2023 a agosto de 2026), critério em que cada planilha anual é completa. A data do fato é usada apenas para os padrões de mês, dia da semana e período do dia. Usar a data do fato para delimitar o período subestimaria os anos recentes, porque fatos desses anos ainda serão registrados com atraso.

3.2 Ferramentas e processo de desenvolvimento

O desenvolvimento seguiu um processo iterativo, com as tarefas organizadas no ClickUp. O código foi versionado no GitHub e conectado ao Databricks por uma pasta Git, e cada notebook documenta em células de texto as decisões tomadas. A Tabela 2 apresenta as ferramentas.

Tabela 2 – Ferramentas utilizadas no desenvolvimento

Categoria	Ferramenta	Uso no projeto
Plataforma	Databricks	Execução dos notebooks e processamento dos dados
Armazenamento	Delta Lake	Tabelas intermediárias e finais, com histórico de versões
Governança	Unity Catalog	Organização do catálogo pi6, controle de acesso e registro do modelo
Tratamento de dados	Python, pandas e PySpark	ETL, agregações e cálculos
Geoprocessamento	GeoPandas, Shapely e API Overpass	Zoneamento e tratamento das coordenadas
Correspondência de nomes	RapidFuzz	Comparação aproximada de nomes de bairros
Localização de bairros	Nominatim (OpenStreetMap) e Google Maps	Coordenadas dos bairros na verificação manual
Aprendizado de máquina	scikit-learn e XGBoost	Treinamento e avaliação dos classificadores
Experimentos	MLflow	Registro de parâmetros, métricas e modelos
Interface	Streamlit, Databricks Apps e SQL Warehouse	Aplicativo de consulta dos resultados agregados por zona
Versionamento e gestão	GitHub e ClickUp	Controle do código e das tarefas

Fonte: Elaborado pelas autoras (2026).

3.3 Arquitetura e organização do pipeline

A solução é um pipeline de sete notebooks, cada um com uma responsabilidade, executados em sequência (Tabela 3). Todas as tabelas ficam no catálogo pi6 do Unity Catalog. A tabela de correspondência do número do boletim fica em um esquema separado (dados_ssp_zonas_restrito), como explicado na seção 3.10.

Tabela 3 – Etapas do pipeline e tabelas produzidas

Notebook	Função	Saída (esquema pi6.dados_ssp_zonas)
00_zoneamento_bairros	Define o centro de cada município e calcula a zona dos bairros do OSM, dos setores censitários e dos bairros localizados manualmente	bairros_zona; setores_zona; bairros_revisados_zona; referencia_centro_municipio
01_etl_pipeline	Extrai e trata os registros da SSP-SP, retira campos desnecessários e pseudonimiza o número do boletim	ocorrencias_ddm (e mapa_pseudonimo_bo no esquema restrito)

Notebook	Função	Saída (esquema pi6.dados_ssp_zonas)
02_populacao_normalizacao	Agrega população e indicadores por zona, liga os bairros da SSP-SP às zonas e calcula a taxa	populacao_zonas; bairros_ssp_x_zona; taxa_ocorrencias_zonas
03_criacao_classes_historicas	Calcula os tercis e atribui a classe histórica de cada zona	classes_historicas_zonas
04_analise_exploratoria	Análise temporal, territorial e socioeconômica	Somente leitura
05_modelagem_ml	Avalia os classificadores e registra os experimentos	Experimentos no MLflow, modelo no Unity Catalog e tabelas de resultados para o aplicativo (modelo_resultados, modelo_previsoes_zonas, modelo_permutacoes, modelo_importancias)
06_tabelas_app	Prepara contagens agregadas por zona, uma dimensão por vez, para o aplicativo, e confere se os totais batem com a base	painel_ocorrencias_agregadas

Fonte: Elaborado pelas autoras (2026).

Os notebooks 00 e 01 não dependem um do outro; os dois precisam terminar antes do 02, e a partir daí a execução é sequencial (02, 03, 04 e 05). O 06 roda depois do 03 e prepara as tabelas lidas pelo aplicativo.

3.4 Construção do zoneamento territorial

Não existe uma divisão oficial de Sorocaba e Votorantim em zonas Norte, Sul, Leste, Oeste e Centro, nem na prefeitura nem no IBGE. Por isso, as zonas são **calculadas** por uma regra única e reprodutível, aplicada da mesma forma aos dois municípios:

a) define-se um ponto de referência para o centro de cada município: o bairro "Centro" do OpenStreetMap; se ele não existir, o ponto que o OpenStreetMap usa para marcar a cidade; e, só em último caso, o ponto médio de todos os bairros;

b) as coordenadas são convertidas para o sistema SIRGAS 2000 / UTM 23S (EPSG:31983), que permite medir distâncias em metros;

c) calcula-se a distância e a direção (ângulo, medido a partir do norte no sentido horário) de cada ponto até o centro;

d) pontos a até 1.500 m do centro formam a zona Centro; os demais são classificados pela direção: Norte (de 315° a 45°), Leste (de 45° a 135°), Sul (de 135° a 225°) e Oeste (de 225° a 315°).

Em Sorocaba, o centro é o bairro "Centro" do OpenStreetMap. Em Votorantim, o OpenStreetMap não tem um bairro com esse nome. Uma versão anterior do pipeline usava como alternativa o ponto médio dos bairros, mas a verificação feita em 08/10/2026 mostrou que esse ponto ficava a 1.705 m do centro da cidade, fora do raio da zona Centro. Por isso, a regra passou a usar o ponto que marca a cidade no OpenStreetMap; em Sorocaba, esse ponto fica a cerca de 95 m do bairro Centro, o que mostra que os dois critérios são equivalentes.

O raio de 1.500 m é um parâmetro metodológico, escolhido como ordem de grandeza da área central de cidades de porte médio e aplicado igualmente aos dois municípios, para manter um critério único. Ele não foi calculado a partir dos dados, e a sensibilidade dos resultados a esse valor não foi testada; essa limitação é discutida na seção 4.6.

A regra é aplicada a três conjuntos de pontos: os 789 bairros do OpenStreetMap (661 de Sorocaba e 128 de Votorantim, extraídos em 08/10/2026), o centro geométrico de cada um dos 1.363 setores censitários (1.148 de Sorocaba e 215 de Votorantim), obtidos da malha de setores do Censo 2022 (IBGE, [2022]) e os bairros localizados manualmente na verificação descrita na seção 3.5. Assim, a população (que vem dos setores) e os registros (que vêm dos bairros) passam pela mesma regra de ângulo e distância, ainda que a partir de pontos diferentes.

Em Votorantim, o centro da cidade fica próximo da divisa norte do município, com Sorocaba. Com a referência no lugar correto, todos os bairros na direção norte ficam a menos de 1.500 m do centro e entram na zona Centro, e a zona Norte fica com apenas um setor censitário (266 moradores) e nenhum bairro. Ela foi mantida na tabela e marcada como "Dados insuficientes" (seção 3.7). A Tabela 4 mostra o resultado do zoneamento.

Tabela 4 – Bairros do OpenStreetMap e setores censitários por zona

Município	Zona	Bairros (OSM)	Setores censitários	População (Censo 2022)
Sorocaba	Centro	55	72	28.435
Sorocaba	Norte	241	452	322.946
Sorocaba	Leste	137	165	99.876
Sorocaba	Sul	49	97	49.322
Sorocaba	Oeste	179	362	223.103
Votorantim	Centro	32	41	26.142
Votorantim	Norte	0	1	266
Votorantim	Leste	22	40	21.041

Município	Zona	Bairros (OSM)	Setores censitários	População (Censo 2022)
Votorantim	Sul	44	63	40.653
Votorantim	Oeste	30	70	39.821

Fonte: Elaborado pelas autoras (2026).

3.5 Correspondência entre os bairros dos boletins e as zonas

Os boletins informam o bairro por escrito, sem coordenadas utilizáveis na análise, e os nomes nem sempre coincidem com os do OpenStreetMap (acentos, abreviações, prefixos como "Jardim" ou "Vila"). A ligação é feita em duas etapas. No notebook 01, os nomes são padronizados e grafias diferentes do mesmo bairro dentro da própria base da SSP-SP são unificadas por comparação aproximada, com pontuação mínima de 85%. No notebook 02, cada bairro da SSP-SP é comparado com os bairros do OpenStreetMap, aceitando-se candidatos com pontuação mínima de 75%, e herda a zona do bairro correspondente.

Para responder como esses vínculos foram verificados, o grupo conferiu manualmente, par a par, os 131 bairros ligados por nome apenas parecido (pontuação de 75 a 99). O resultado está na Tabela 5.

Tabela 5 – Verificação manual das correspondências por nome parecido

Pontuação	Pares	Corretos	Errados	Duvidosos	% de erro
75 a 79	41	21	17	3	41%
80 a 84	36	12	21	3	58%
85 a 89	20	10	7	3	35%
90 a 94	18	15	2	1	11%
95 a 99	16	14	1	1	6%
Total	**131**	**72**	**48**	**11**	**37%**

Fonte: Elaborado pelas autoras (2026).

Os erros aparecem em todas as faixas, até acima de 90%: por exemplo, "Jardim Refugio" estava ligado a "Jardim Rubi", "Vila Santa Rita" a "Vila Santa Cruz" e "Vila Mariza" a "Vila Maria". Como nenhum limiar resolve o problema sozinho, a correspondência passou a seguir estas regras:

a) nomes idênticos (pontuação 100) são aceitos;

b) nomes parecidos só são aceitos se constarem como conferidos e corretos na lista de verificação (72 pares);

c) os bairros ligados ao bairro errado, os duvidosos e os que não tinham correspondência foram localizados por coordenada, uma a uma, e a sua zona foi calculada pela mesma regra de ângulo e distância;

d) um par com nome parecido que não tenha sido verificado não é aceito automaticamente: fica sem zona e gera um aviso no notebook, para ser revisado.

A localização por coordenada envolveu 139 bairros. Primeiro, uma busca automática no Nominatim, o serviço de busca de endereços do OpenStreetMap (NOMINATIM, 2026), restrita aos limites de cada município. Os resultados com nome equivalente ao do boletim foram aceitos (48 bairros); os demais foram buscados manualmente no Google Maps (GOOGLE, 2026) e conferidos pelo endereço reverso do OpenStreetMap, para garantir que o ponto estava no município correto (46 bairros). Bairros não encontrados ou que não puderam ser confirmados foram descartados (39), e seis registros não eram localizáveis (bairro "Não Informado", "Área Rural" e textos que não são nomes de bairro). No caso do bairro "Centro" de Votorantim, adotou-se como coordenada o próprio ponto de referência do centro da cidade. A lista completa, com fonte, data e decisão de cada bairro, está no repositório (pasta dados_auxiliares). O resultado é apresentado na Tabela 6.

Tabela 6 – Como cada bairro da SSP-SP recebeu a sua zona

Método	Bairros	%
Nome idêntico	305	59,3%
Nome parecido, conferido como correto	72	14,0%
Revisão manual: localizado por coordenada	94	18,3%
Revisão manual: sem localização (sem zona)	43	8,4%
Total	**514**	**100%**

Fonte: Elaborado pelas autoras (2026).

Com a verificação, os registros sem zona caíram de 412 (16,4% da base) para **121 (4,8%)**. Desses 121, 49 são boletins sem bairro informado, que não poderiam ser localizados de nenhuma forma. Nenhum registro sem zona foi atribuído por suposição.

3.6 Indicadores populacionais e socioeconômicos

A população de cada zona é a soma da população (variável V0001 do Censo 2022) dos seus setores censitários. Como a população é o denominador da taxa, ela é obrigatória: se o dado não estiver disponível, a execução é interrompida, sem estimativas. Os demais indicadores são opcionais e ficam vazios se a fonte faltar, também sem estimativas. A taxa de registros é calculada pela equação (1).

$$\text{Taxa por 10.000 habitantes} = (\text{registros da zona} \div \text{população da zona}) \times 10.000 \quad (1)$$

Os indicadores proporcionais foram recalculados para cada zona: primeiro somam-se o numerador e o denominador de todos os setores da zona e só depois calcula-se a proporção. Isso evita a soma ou a média simples de percentuais de setores com populações diferentes, que distorceria o resultado. A idade média é uma média ponderada pelos moradores de cada faixa etária (variáveis V01031 a V01041), usando o ponto médio de cada faixa (por exemplo, 34,5 anos para a faixa de 30 a 39 anos e 75 anos para a faixa aberta de 70 anos ou mais), conforme a equação (2).

$$\text{Idade média} = \Sigma\,(\text{moradores da faixa} \times \text{ponto médio da faixa}) \div \Sigma\,\text{moradores} \quad (2)$$

A taxa de alfabetização considera as pessoas de 15 anos ou mais (V00900, sabem ler e escrever; V00901, não sabem), a chefia feminina considera os responsáveis pelos domicílios (V01062, homens; V01063, mulheres) e a densidade domiciliar considera os moradores (V00005) e os domicílios particulares permanentes ocupados (V00001), conforme as equações (3) a (5).

$$\text{Taxa de alfabetização} = V00900 \div (V00900 + V00901) \quad (3)$$

$$\%\ \text{de chefia feminina} = V01063 \div (V01062 + V01063) \times 100 \quad (4)$$

$$\text{Moradores por domicílio} = V00005 \div V00001 \quad (5)$$

A vulnerabilidade social vem do IPVS 2022, que classifica cada setor censitário em seis grupos, de 1 (baixíssima vulnerabilidade) a 6 (muito alta), combinando a renda do responsável pelo domicílio, a alfabetização e características do ciclo de vida familiar; setores com menos de 36 domicílios ou especiais, como quartéis e presídios, não são classificados (SEADE, 2026). O IPVS usa a mesma malha de setores do Censo 2022, o que permite a ligação direta pelo código do setor. O indicador usado é a porcentagem da população da zona que mora em setores de vulnerabilidade alta ou muito alta (grupos 5 e 6), ponderada pela população de cada setor e calculada só sobre os setores classificados, conforme a equação (6). Ele foi incluído porque a renda, uma dimensão importante, não é publicada pelo Censo 2022 no nível de setor; o IPVS é o indicador oficial disponível que a incorpora.

% em vulnerabilidade alta = população dos setores IPVS 5 e 6 ÷ população dos setores classificados (6)

A variável cor ou raça, embora disponível no Censo, foi deliberadamente excluída: usá-la para caracterizar zonas criaria uma associação direta entre composição racial e classificação, com potencial discriminatório.

3.7 Classificação histórica das zonas

A classe histórica de cada zona é calculada por fórmula, sem modelo: a taxa da equação (1) é comparada com os tercis (P33 e P67) das taxas de todas as zonas classificáveis, recalculados a cada execução. Zonas com menos de 5 registros no período são marcadas como "Dados insuficientes" e não entram no cálculo dos tercis. Esse mínimo evita classificar zonas com base em pouquíssimos casos, em que um único registro mudaria a classe, e reduz a exposição de conjuntos muito pequenos. Zonas que têm moradores, mas nenhum registro, também entram na tabela e recebem essa marcação, em vez de serem omitidas.

3.8 Modelagem

A modelagem é experimental e responde a uma pergunta: as características das zonas permitem reproduzir a classe histórica calculada na seção 3.7? Cada exemplo é uma zona, e não um registro individual. O total de registros e a população ficam fora das variáveis de entrada, porque formam a própria taxa que define a classe; incluí-los seria vazamento de dados. O município também ficou fora: como as zonas Alto se concentram em um município, o modelo poderia aprender "município, logo classe", em vez de associar o perfil da zona à classe.

As variáveis de entrada foram definidas antes de olhar o resultado, uma por dimensão, para evitar escolher variáveis pelo desempenho, o que com tão poucas zonas produziria resultados bons por acaso:

a) onde: porcentagem de registros em residência;

b) quando, na hora: porcentagem de registros à noite, calculada só sobre os registros com período conhecido (se os registros sem horário entrassem na conta, uma zona com mais registros incompletos teria porcentagens menores em todos os períodos, e a variável mediria a qualidade do registro);

c) quando, no dia: porcentagem de registros no sábado ou domingo;

d) população: idade média;

e) domicílio: moradores por domicílio.

Essa é a versão v3 do protocolo. A versão v4 acrescenta uma sexta variável, a porcentagem da população em vulnerabilidade alta (IPVS), decidida antes de ver o seu resultado, e mantém todo o resto igual. As duas versões são relatadas, e a v4 é a execução final.

Foram avaliados três classificadores (Árvore de Decisão, Random Forest e XGBoost), com configurações fixas, e um classificador de referência (DummyClassifier), que sorteia a classe na proporção das classes do treino. Como um único sorteio pode acertar muito ou pouco por sorte, o desempenho da referência é a média de 200 sorteios. O XGBoost usou parâmetros fixos (200 árvores, profundidade máxima 3 e taxa de aprendizado 0,1): uma busca de parâmetros honesta exigiria repeti-la dentro de cada rodada da validação, com apenas oito zonas, o que seria escolher configurações com base em ruído (VARMA; SIMON, 2006).

A avaliação usou **validação cruzada leave-one-out**: cada zona é testada uma vez por um modelo treinado com as demais, e as métricas (acurácia e precisão, recall e F1-score macro) são calculadas sobre as previsões de todas as zonas. Uma divisão única em treino e teste deixaria só duas ou três zonas no teste, e cada acerto valeria mais de 30 pontos percentuais. O melhor classificador é o de maior F1-score macro, com desempate pela acurácia e depois pelo modelo mais simples.

Para saber se o resultado é melhor que o acaso, usou-se um **teste de permutação** que inclui a escolha do modelo: as classes são embaralhadas entre as zonas, os três classificadores são avaliados de novo e guarda-se o maior F1-score, como foi feito com os dados reais. O número de repetições (entre 200 e 1.000) é ajustado ao tempo de execução e fica registrado. O p-valor é a proporção de repetições em que "o melhor de três modelos sem nada real para aprender" chegou a um F1-score igual ou maior que o real. Incluir a escolha no teste é necessário porque escolher o melhor de três modelos já dá ao acaso três chances; testar só o escolhido tornaria o p-valor otimista.

Todos os modelos ficam registrados como execuções no MLflow, mas **só o melhor** é registrado no Unity Catalog, com o nome

PI6_ClassificadorPerfilHistoricoZona. Ele é treinado com todas as zonas, e marcadores no MLflow informam se foi selecionado e se superou a referência. Uma versão anterior do código registrava sempre o XGBoost, independentemente do desempenho; isso foi corrigido.

3.9 Procedimentos de verificação

As verificações ficam nos próprios notebooks e rodam a cada execução:

a) extração: estrutura das planilhas, tipos de dados, valores ausentes, total de registros e de boletins distintos e cruzamento entre ano de registro e ano do fato;

b) proteção de dados: uma trava interrompe a gravação se o número do boletim, o logradouro ou as coordenadas chegarem à base de análise, e a pseudonimização confere que dois boletins diferentes nunca recebem o mesmo código;

c) zoneamento: método usado para o centro de cada município, distribuição de bairros e setores por zona e aviso de zonas vazias; coordenadas da planilha de localização fora da região são rejeitadas;

d) correspondência: contagem de como cada bairro recebeu a zona e aviso de pares com nome parecido não verificados;

e) classes: valores do P33 e do P67, número de zonas por classe e zonas com dados insuficientes;

f) modelagem: lista de variáveis de entrada (sem total de registros, população e município), comparação com a referência e teste de permutação;

g) aplicativo: o notebook 06 confere se cada dimensão agregada soma o total de registros da base e interrompe a gravação se os totais divergirem.

O plano de testes da disponibilização dos resultados está na seção 3.10 e os resultados obtidos, na seção 4.5.

3.10 Disponibilização dos resultados

Os resultados ficam disponíveis no ambiente Databricks, de forma agregada por zona: nas tabelas do Unity Catalog (principalmente classes_historicas_zonas e populacao_zonas), nos notebooks com as análises, nos experimentos do MLflow e

em um aplicativo de consulta. Nenhum resultado mostra registros individuais ou pontos de ocorrência. A interface do PI5 (aplicação em Streamlit hospedada em servidor próprio) não foi mantida; no PI6, ela foi substituída por um aplicativo publicado no próprio Databricks.

O aplicativo, chamado pi6-zonas, foi desenvolvido em Streamlit e publicado com o recurso Databricks Apps. Ele tem quatro páginas: O projeto, com o resumo do trabalho; Painel por região, com filtros de município e zona; Teste com IA, com os resultados da modelagem em linguagem acessível; e Como fizemos e LGPD, com o método, as medidas de proteção de dados e as limitações. O acesso exige login no workspace do projeto, e todas as páginas lembram que a classificação é um retrato do período, para uso interno.

Por privilégio mínimo, o aplicativo não lê a base de ocorrências. Ele consulta, por meio de um SQL Warehouse, apenas tabelas agregadas: classes_historicas_zonas, populacao_zonas, as tabelas de resultados da modelagem gravadas pelo 05 e a tabela painel_ocorrencias_agregadas, preparada pelo 06 com contagens por zona de uma dimensão por vez, para que nenhuma combinação de categorias descreva um boletim específico. A identidade de serviço do aplicativo recebe somente permissão de leitura nessas tabelas e nenhuma permissão na base de ocorrências ou no esquema restrito. A publicação está documentada no Deploy Guide do projeto, e o uso, no Guia de Uso.

O plano de testes da Tabela 7 verifica se as informações disponibilizadas são consistentes com o processamento.

Tabela 7 – Plano de testes da disponibilização

Teste	Procedimento	Resultado esperado
Tabelas	Consultar classes_historicas_zonas no Unity Catalog	10 zonas, com classe, taxa, população e período
Coerência	Recalcular a taxa de uma zona a partir das ocorrências e da população	Mesmo valor da tabela
Proteção	Conferir as colunas de ocorrencias_ddm	Sem número do boletim, logradouro ou coordenadas
Acesso	Consultar o catálogo pi6 com um usuário sem permissão	Acesso negado
Modelo	Conferir no MLflow o modelo registrado e os marcadores	Modelo de maior F1-score, com os marcadores de seleção
Aplicativo	Abrir o aplicativo com um usuário do workspace e navegar pelas quatro páginas	Páginas carregadas, com os mesmos valores das tabelas
Permissões do aplicativo	Conferir as permissões da	Só leitura nas tabelas agregadas;

Teste	Procedimento	Resultado esperado
	identidade de serviço do aplicativo no Unity Catalog	nenhum acesso a ocorrencias_ddm e ao esquema restrito

Fonte: Elaborado pelas autoras (2026).

3.11 Proteção e governança dos dados

O tratamento foi definido a partir da finalidade acadêmica e analítica do projeto. Embora o art. 4º, II, "b", da LGPD trate do uso exclusivamente acadêmico, essa hipótese não foi usada para dispensar as medidas de proteção, porque o processamento parte de microdados da SSP-SP que, mesmo sem o nome da vítima, podem tornar uma ocorrência identificável pela combinação de campos (BRASIL, 2018). A Tabela 8 resume os campos tratados.

Tabela 8 – Campos da SSP-SP: mantidos, transformados e removidos

Campo da SSP-SP	Decisão	Motivo
Município, delegacia, ano de registro	Mantido	Delimitam a base e o período
Data e hora do fato, período, dia da semana	Mantido	Padrões temporais (análise e modelagem)
Bairro	Mantido	Necessário para atribuir a zona
Local, natureza e rubrica	Mantido	Perfil das ocorrências
Número do boletim	Pseudonimizado	Permite contar boletins distintos sem expor o número
Logradouro	Removido	Não é usado; aumentaria o risco de identificação
Latitude e longitude	Removidas	Não são usadas; indicariam o local exato, muitas vezes a residência

Fonte: Elaborado pelas autoras (2026).

A **minimização** (princípio da necessidade, art. 6º, III) retira o logradouro e as coordenadas antes de qualquer gravação, porque a zona vem do nome do bairro e nenhuma etapa precisa desses campos. Uma trava no código impede que eles cheguem à base de análise.

A **pseudonimização** (art. 13, § 4º) troca o número do boletim por um código gerado pela função HMAC-SHA256, que combina o número com uma chave secreta (KRAWCZYK; BELLARE; CANETTI, 1997). O mesmo boletim sempre recebe o mesmo código, o que permite contar boletins distintos. Usar uma chave, e não uma função de hash simples, é necessário porque os números de boletim são públicos: sem chave, qualquer pessoa poderia recalcular o código e descobrir o boletim. A chave fica no gerenciador de segredos do Databricks, fora do código. A correspondência entre código e número do boletim fica em uma tabela separada, em

um esquema próprio (dados_ssp_zonas_restrito), que nenhum dos notebooks de análise lê. Como a associação continua possível para quem tem acesso a essa tabela, o dado é pseudonimizado, e não anonimizado.

Na **divulgação**, os resultados são apresentados só por zona, nenhuma figura mostra pontos de ocorrência e zonas com menos de 5 registros não recebem classe. A versão anterior da análise exploratória tinha um mapa com um ponto por ocorrência, que foi substituído por um diagrama agregado das zonas.

Na **segurança** (art. 46), os dados ficam no Databricks, com armazenamento em Delta Lake e acesso controlado pelo Unity Catalog: durante o desenvolvimento, um usuário do mesmo workspace sem permissão concedida teve o acesso ao catálogo pi6 negado. O esquema dados_ssp_zonas_restrito, que guarda a tabela de correspondência entre o código pseudonimizado e o número do boletim, tem acesso restrito às duas autoras. O código fica em repositório privado no GitHub, que não guarda dados de ocorrências nem credenciais (arquivos de credencial são bloqueados no versionamento). A pasta dados_auxiliares do repositório contém apenas nomes de bairros e coordenadas públicas.

3.12 Retenção e descarte dos dados

A retenção está ligada à finalidade acadêmica do PI6 (arts. 15 e 16 da LGPD). O plano definido pelo grupo mantém os dados necessários ao desenvolvimento, à validação e à documentação até a banca final, com eliminação em até 30 dias depois dela. O descarte abrange as tabelas com registros individuais (ocorrencias_ddm e mapa_pseudonimo_bo), as tabelas da versão por bairro (esquema pi6.dados_ssp), cópias locais e arquivos temporários. No Delta Lake, além de excluir as tabelas, é preciso eliminar as versões antigas mantidas pelo histórico, para que os dados não continuem acessíveis por elas. A chave de pseudonimização também deve ser excluída. O descarte deve ser registrado, com data e responsável.

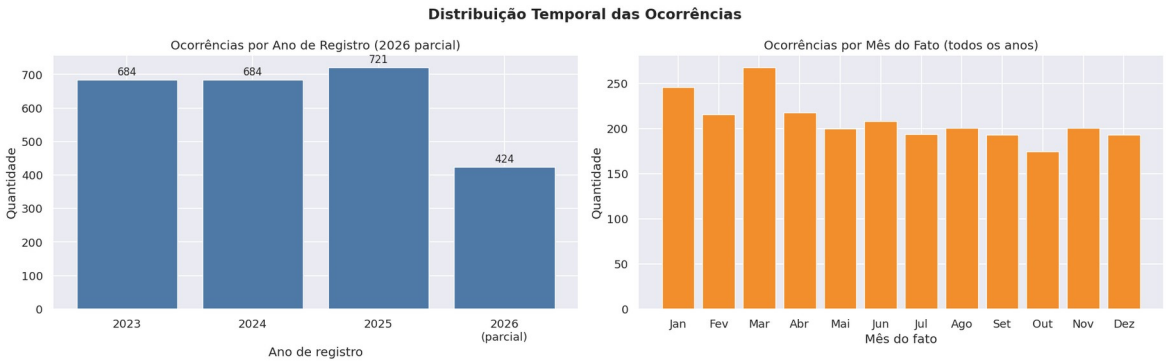
4 RESULTADOS E DISCUSSÃO

Este capítulo apresenta os resultados da execução do pipeline com a base extraída em 08/10/2026: a análise exploratória, a classificação histórica das zonas, a modelagem, os testes, a validação com as partes interessadas e as limitações.

4.1 Análise exploratória dos dados

A base tem 2.513 registros (2.445 boletins distintos). Pelo ano de registro, foram 684 em 2023, 684 em 2024, 721 em 2025 e 424 em 2026, ano que inclui só os meses publicados até agosto. A Figura 1 mostra essa distribuição e a distribuição pelo mês do fato.

Figura 1 – Registros por ano de registro e por mês do fato



Fonte: Elaborado pelas autoras (2026), com dados do pipeline no Databricks.

A Tabela 9 cruza o ano de registro com o ano do fato. A maior parte dos boletins (2.352, ou 93,6%) foi registrada no mesmo ano em que o fato aconteceu; 161 (6,4%) foram registrados em ano posterior, e 90 (3,6%) referem-se a fatos anteriores a 2023, o mais antigo de julho de 2006. Esse registro tardio ajuda a entender a subnotificação discutida na seção 2.1: o fato só entra na estatística quando é comunicado.

Tabela 9 – Registros por ano de registro e ano do fato

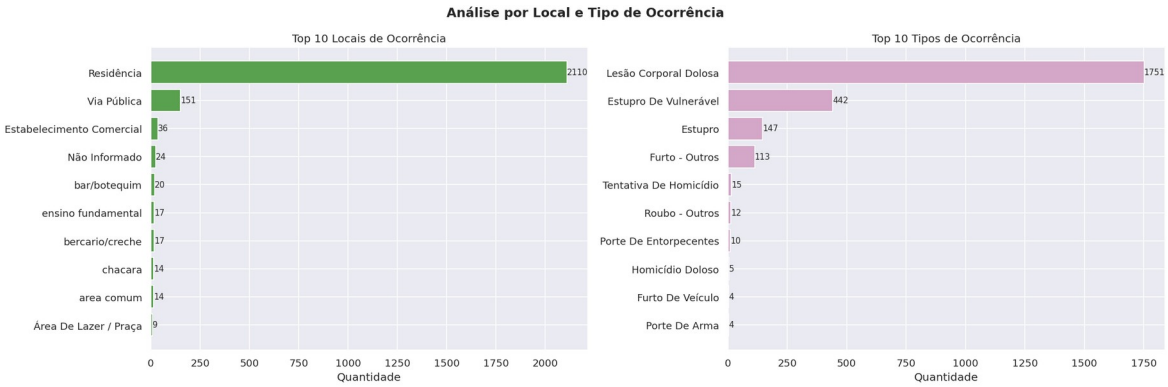
Ano de registro	Fato antes de 2023	2023	2024	2025	2026	Total
2023	40	644	–	–	–	684
2024	15	17	652	–	–	684
2025	20	5	27	669	–	721
2026	15	2	3	17	387	424
Total	**90**	**668**	**682**	**686**	**387**	**2.513**

Fonte: Elaborado pelas autoras (2026).

Quanto ao local, 2.110 registros (84,0%) ocorreram em residência, 151 em via pública e 36 em estabelecimento comercial. Quanto à natureza, predominam lesão

corporal dolosa (1.751), estupro de vulnerável (442) e estupro (147), conforme a Figura 2. A predominância de ocorrências em residência e de lesão corporal é compatível com o contexto de violência doméstica e familiar tratado pela Lei Maria da Penha (BRASIL, 2006).

Figura 2 – Principais locais e naturezas das ocorrências

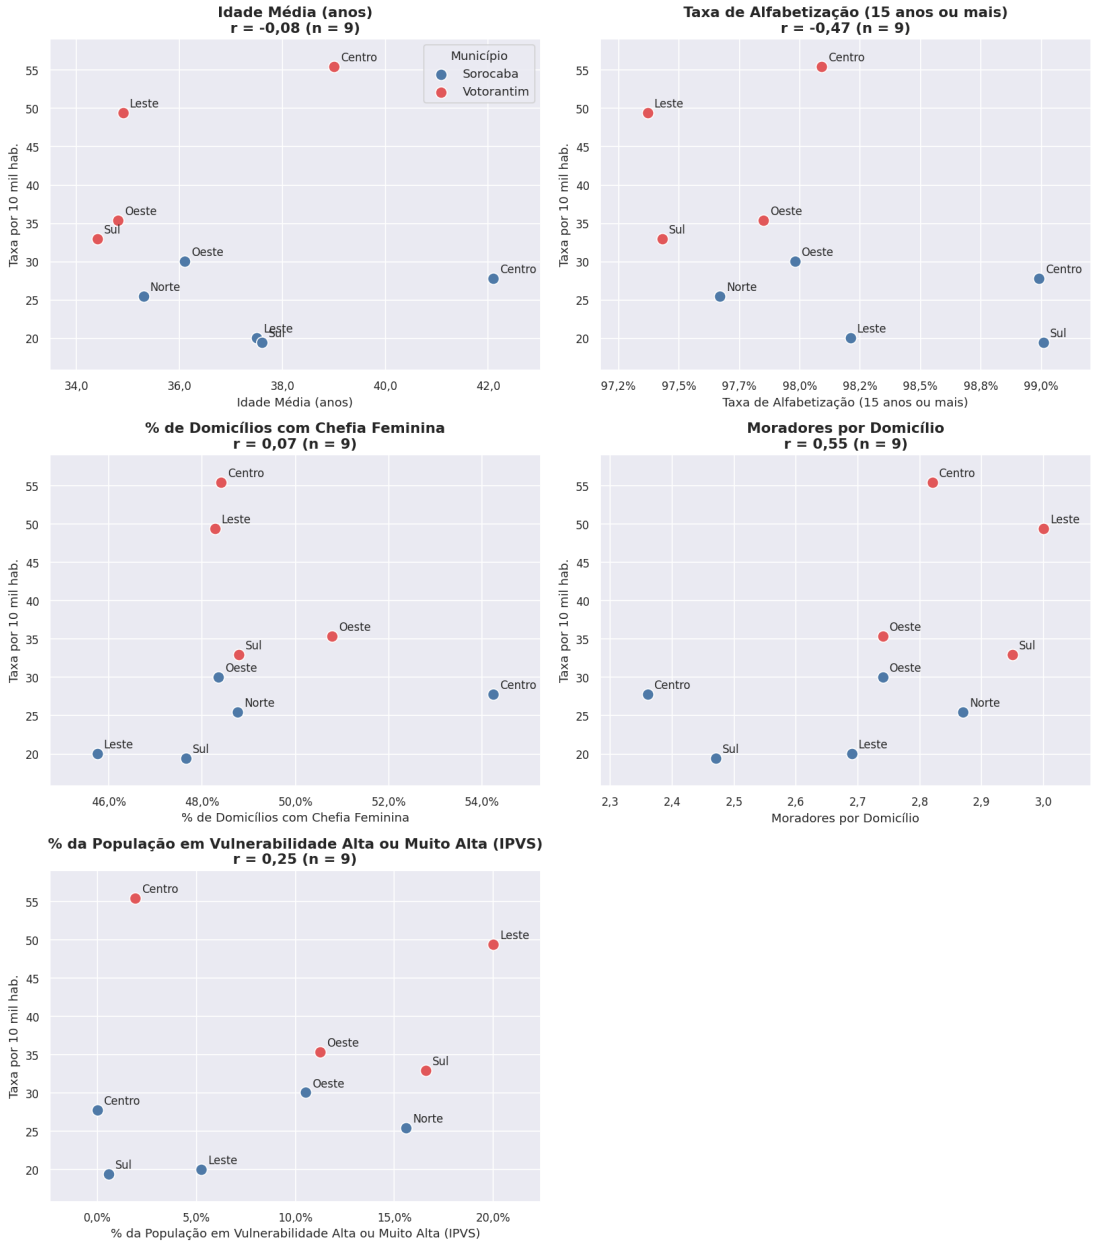


Fonte: Elaborado pelas autoras (2026), com dados do pipeline no Databricks.

Sobre a qualidade dos dados, 581 registros (23,1%) não têm a hora do fato; para parte deles, o período do dia vem informado pela SSP-SP, e a proporção sem período conhecido por zona varia de 2,8% a 14,5%. É maior nas zonas de Sorocaba (8,9% a 14,5%) do que nas de Votorantim (2,8% a 7,6%), uma diferença entre as duas bases de registro que justifica calcular as variáveis de período só sobre os registros com período conhecido (seção 3.8). Após a verificação dos bairros, 121 registros (4,8%) ficaram sem zona.

A Figura 3 cruza os indicadores socioeconômicos com a taxa de cada zona. As correlações foram fracas ou moderadas: idade média −0,08; taxa de alfabetização −0,47; chefia feminina 0,07; moradores por domicílio 0,55; e porcentagem da população em setores de vulnerabilidade alta ou muito alta do IPVS 0,25. Com nove zonas, uma correlação só seria estatisticamente significativa ao nível de 5% se fosse maior que cerca de 0,67 em valor absoluto, o que não ocorreu em nenhum caso. Essas associações são apenas descritivas e não indicam causa.

Figura 3 – Indicadores socioeconômicos e taxa de registros por zona



Fonte: Elaborado pelas autoras (2026), com dados do pipeline no Databricks.

O caso do IPVS ilustra bem essa limitação. A zona com a maior taxa, o Centro de Votorantim, tem uma das menores porcentagens de população em setores de vulnerabilidade alta ou muito alta, enquanto a zona Leste do mesmo município tem a maior porcentagem e também uma taxa alta. Ou seja, a vulnerabilidade social medida pelo IPVS, sozinha, não explica a diferença de taxas entre as zonas. Outros fatores que não fazem parte da base, como o acesso à delegacia e a disposição para registrar (seção 2.1), também podem influenciar a taxa, e não puderam ser testados com estes dados.

4.2 Classificação histórica das zonas

A Tabela 10 apresenta o resultado principal do projeto: a taxa de cada zona e a sua classe histórica. Os tercis calculados sobre as nove zonas classificáveis foram P33 = 27,00 e P67 = 33,78 registros por 10.000 habitantes, resultando em três zonas em cada classe. A zona Norte de Votorantim, com 266 moradores e nenhum registro, ficou como "Dados insuficientes".

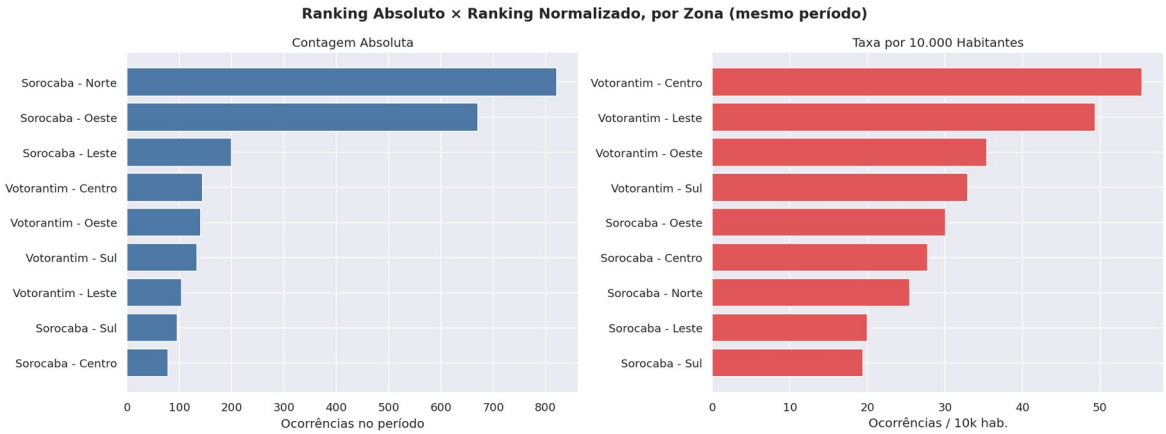
Tabela 10 – Registros, população, taxa e classe histórica por zona (registros de 2023 a agosto de 2026)

Município	Zona	Registros	População	Taxa por 10 mil hab.	Classe
Votorantim	Centro	145	26.142	55,47	Alto
Votorantim	Leste	104	21.041	49,43	Alto
Votorantim	Oeste	141	39.821	35,41	Alto
Votorantim	Sul	134	40.653	32,96	Médio
Sorocaba	Oeste	671	223.103	30,08	Médio
Sorocaba	Centro	79	28.435	27,78	Médio
Sorocaba	Norte	822	322.946	25,45	Baixo
Sorocaba	Leste	200	99.876	20,02	Baixo
Sorocaba	Sul	96	49.322	19,46	Baixo
Votorantim	Norte	0	266	–	Dados insuficientes

Fonte: Elaborado pelas autoras (2026).

A normalização pela população muda a leitura dos dados (Figura 4). Pela contagem absoluta, as zonas com mais registros são de Sorocaba, como a Norte, com 822. Pela taxa, as quatro maiores são de Votorantim, e todas as zonas de Votorantim classificadas ficaram nas classes Alto ou Médio, enquanto as de Sorocaba ficaram em Médio ou Baixo. Sem a normalização, a análise destacaria as zonas mais populosas e esconderia a concentração relativa observada em Votorantim, como discutido na seção 2.2.

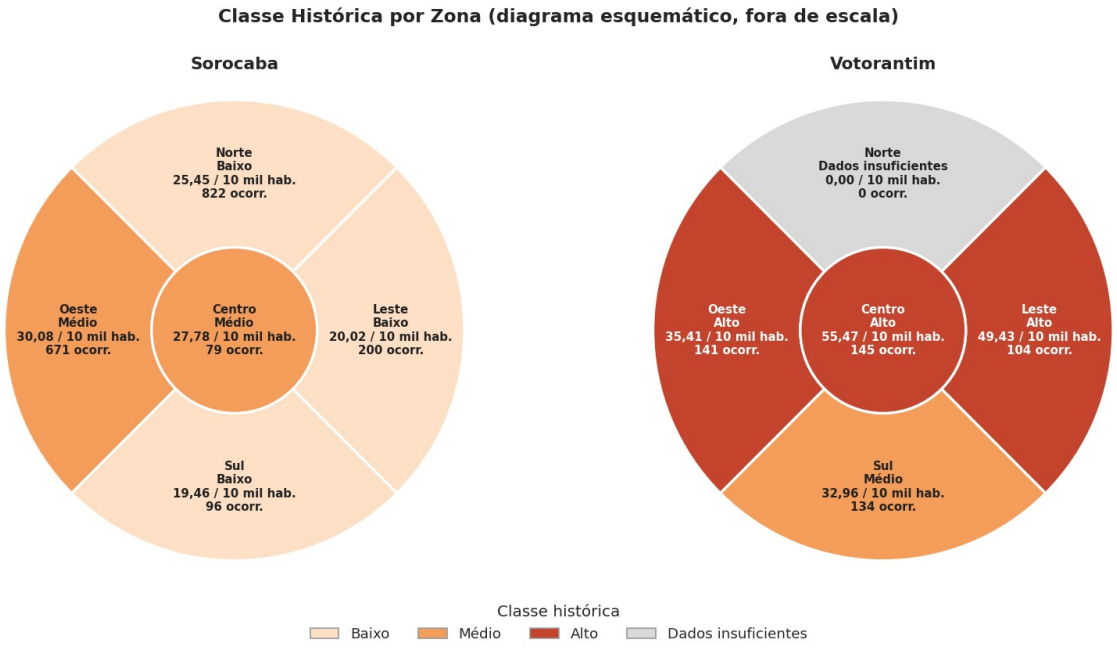
Figura 4 – Ordenação das zonas pela contagem absoluta e pela taxa por 10.000 habitantes



Fonte: Elaborado pelas autoras (2026), com dados do pipeline no Databricks.

A Figura 5 resume a classificação por meio de um diagrama esquemático, fora de escala, que mostra a lógica do zoneamento (Centro no meio e quadrantes ao redor) sem usar a localização de nenhuma ocorrência.

Figura 5 – Classe histórica por zona (diagrama esquemático)



Fonte: Elaborado pelas autoras (2026), com dados do pipeline no Databricks.

Esses resultados não devem ser lidos como medida de perigo dos territórios. A diferença entre os municípios pode refletir diferenças na ocorrência do fenômeno, mas também no acesso à delegacia e na disposição para registrar (seção 2.1). Além disso, o resultado depende do desenho das zonas (seção 2.2): em Votorantim, a correção da referência central mudou a composição das zonas e as suas taxas. Por isso, a classificação é um insumo interno de análise, e não um rótulo público.

4.3 Desempenho dos modelos de classificação

A Tabela 11 apresenta o desempenho dos modelos nas versões v3 e v4 do protocolo, que tiveram métricas idênticas, com as nove zonas classificáveis e validação leave-one-out.

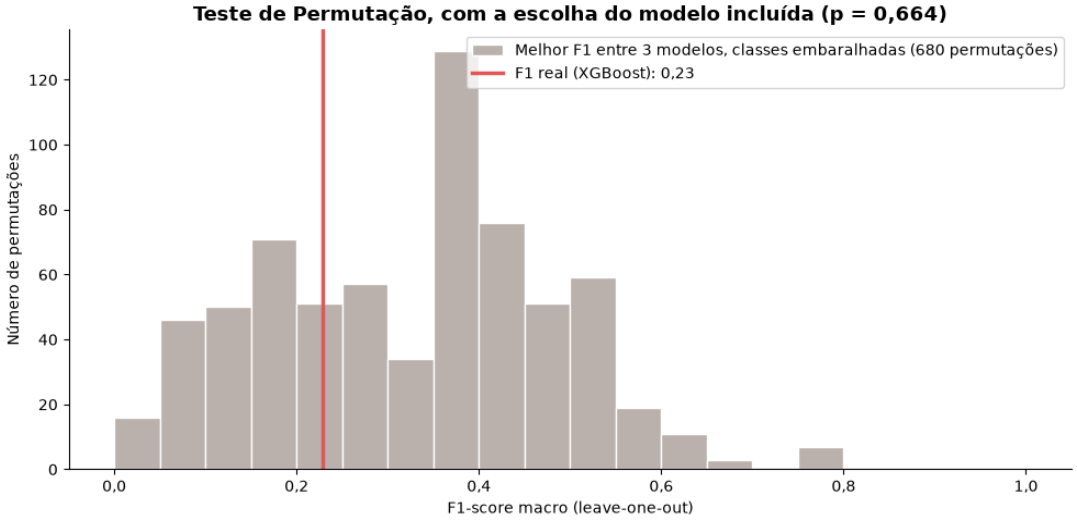
Tabela 11 – Desempenho dos classificadores (validação leave-one-out, 9 zonas, protocolos v3 e v4)

Modelo	Acertos	Acurácia	Precisão	Recall	F1-score
Referência (média de 200 sorteios)	–	0,26	0,16	0,26	0,19
Árvore de Decisão	2 de 9	0,22	0,19	0,22	0,21
Random Forest	2 de 9	0,22	0,19	0,22	0,21
XGBoost (selecionado)	**2 de 9**	**0,22**	**0,25**	**0,22**	**0,23**

Fonte: Elaborado pelas autoras (2026), a partir dos experimentos registrados no MLflow.

O XGBoost teve o maior F1-score (0,23) e foi o modelo registrado no Unity Catalog, mas acertou apenas 2 das 9 zonas. Na execução final, de 15/10/2026 (protocolo v4), o teste de permutação teve 680 repetições incluindo a escolha do modelo, e o melhor F1-score obtido com as classes embaralhadas teve média de 0,33, maior que o resultado real. O p-valor foi de **0,66**: em 66% das repetições, modelos sem nenhuma relação real com as classes chegaram a um resultado igual ou melhor (Figura 6). O resultado, portanto, não se distingue do acaso.

Figura 6 – Teste de permutação: F1-score real e F1-score com as classes embaralhadas



Fonte: Elaborado pelas autoras (2026), com dados do pipeline no Databricks.

Na versão v4, a única mudança em relação à v3 foi a inclusão da sexta variável, a porcentagem da população em setores de vulnerabilidade alta ou muito

alta do IPVS, decidida antes de ver o resultado. Os quatro modelos tiveram exatamente as mesmas métricas da Tabela 11: as previsões de cada zona não mudaram, e o XGBoost continuou com F1-score de 0,23 e 2 acertos em 9 zonas. Na v3, o teste de permutação teve 699 repetições e p-valor de **0,68**; na v4, executada pela última vez em 15/10/2026, o p-valor foi de 0,66, como descrito acima. A pequena diferença vem do próprio sorteio das permutações, cujo número é ajustado ao tempo de execução. Isso é coerente com a correlação fraca do IPVS com a taxa (0,25) observada na seção 4.1: a variável nova não trouxe informação que separasse as classes. No MLflow, a execução do XGBoost da v4 está marcada como selecionada para registro.

Os resultados da modelagem mudaram bastante ao longo do PI6, conforme a base, a unidade territorial e a forma de avaliar (Tabela 12). Os resultados mais altos vieram de execuções com dados ou avaliações que depois se mostraram inadequados: correspondência de bairros sem verificação, zona Centro de Votorantim deslocada, avaliação com duas ou três zonas no teste ou teste de permutação sem incluir a escolha do modelo. Essa instabilidade é, por si só, evidência de que o número de zonas não sustenta um classificador.

Tabela 12 – Histórico das execuções da modelagem

Execução	Unidades	Avaliação	Melhor resultado
02/09, versão por bairro	122 bairros	Treino/teste (31 no teste)	Random Forest: acurácia 0,42
12/09, versão por zona	10 zonas	Treino/teste (3 no teste)	Random Forest: acurácia 0,67
08/10, base atualizada até agosto	10 zonas	Treino/teste (3 no teste)	Random Forest: acurácia 0,33
08/10, leave-one-out, 15 variáveis	10 zonas	Leave-one-out; permutação só do selecionado	Árvore: acurácia 0,70 (p = 0,039)
08/10, protocolo v3, antes da verificação dos bairros	10 zonas	Leave-one-out; permutação com seleção	XGBoost: acurácia 0,40 (p = 0,46)
08/10, protocolo v3 final	9 zonas	Leave-one-out; permutação com seleção	XGBoost: acurácia 0,22 (p = 0,68)
08/10, protocolo v4 (v3 + IPVS)	**9 zonas**	**Leave-one-out; permutação com seleção**	**XGBoost: acurácia 0,22 (p = 0,67)**
15/10, protocolo v4, execução final	9 zonas	Leave-one-out; permutação com seleção	XGBoost: acurácia 0,22 (p = 0,66)

Fonte: Elaborado pelas autoras (2026), a partir dos experimentos registrados no MLflow.

A conclusão é que, com nove zonas e as variáveis disponíveis, não foi possível treinar um classificador que reproduza a classe histórica melhor que o acaso. Esse resultado atende ao objetivo específico de avaliar a aplicação do

aprendizado de máquina considerando as limitações dos dados e reforça que o resultado principal do projeto é a classificação histórica por taxa, que não depende de modelo.

4.4 Validação com as partes interessadas

Em 14/09/2026, o grupo apresentou o projeto à Profa. Evelyn Priscila Santinon Sola, professora e advogada da Fatec Votorantim, para orientação jurídica sobre o uso de dados públicos de ocorrências de violência contra a mulher. As questões envolveram a aplicação da LGPD, a possibilidade de reidentificação, a agregação, os limites da divulgação, a responsabilidade em caso de incidente e a retenção e o descarte dos dados. O registro desse contato, com as respostas recebidas, está no Apêndice A, e a Tabela 13 relaciona as orientações às medidas adotadas.

Tabela 13 – Orientações jurídicas e medidas adotadas

Orientação recebida	Medida adotada	Onde
Para fins acadêmicos, não é necessária autorização adicional, mas o tratamento deve respeitar a finalidade, a boa-fé e o interesse público da divulgação	Finalidade acadêmica e analítica definida; dados usados só para análise territorial	Seções 1.3 e 3.11
Aplicar o princípio da necessidade e excluir antes da agregação os campos que facilitem a reidentificação	Logradouro e coordenadas removidos; número do boletim pseudonimizado; trava no código	Seção 3.11 e notebook 01
Atenção à reidentificação em grupos com poucos registros	Zonas com menos de 5 registros não recebem classe	Seção 3.7
Divulgar só dados agregados e evitar estigmatizar territórios	Resultados por zona, sem pontos de ocorrência; termo "classificação histórica" no lugar de "risco"	Seções 3.10 e 4.2
A instituição é controladora; alunos e orientador executam o tratamento; formalizar compromissos de não divulgação dos dados brutos	Esquema com a tabela de correspondência acessível só às autoras; repositório sem dados. O termo de compromisso ainda não foi formalizado e fica como encaminhamento	Seção 3.11
Definir um plano formal de descarte, com registro da data e da execução	Plano de retenção e descarte em até 30 dias após a banca	Seção 3.12

Fonte: Elaborado pelas autoras (2026).

Não houve contato com a DDM durante o PI6. A última interação com a organização parceira ocorreu no PI5, nas reuniões de 05/03/2026 e 18/03/2026, em que o projeto era apresentado como modelagem preditiva. Desde então, o enquadramento mudou para classificação histórica, e essa mudança ainda não foi apresentada à DDM. Fica como encaminhamento apresentar à Delegada Renata

Zanin os resultados do PI6 por zona, o novo enquadramento e as medidas de proteção de dados, e registrar em ata a sua avaliação sobre a utilidade da classificação para o trabalho da delegacia.

4.5 Resultados dos testes, falhas e correções

A Tabela 14 apresenta o resultado do plano de testes da seção 3.10.

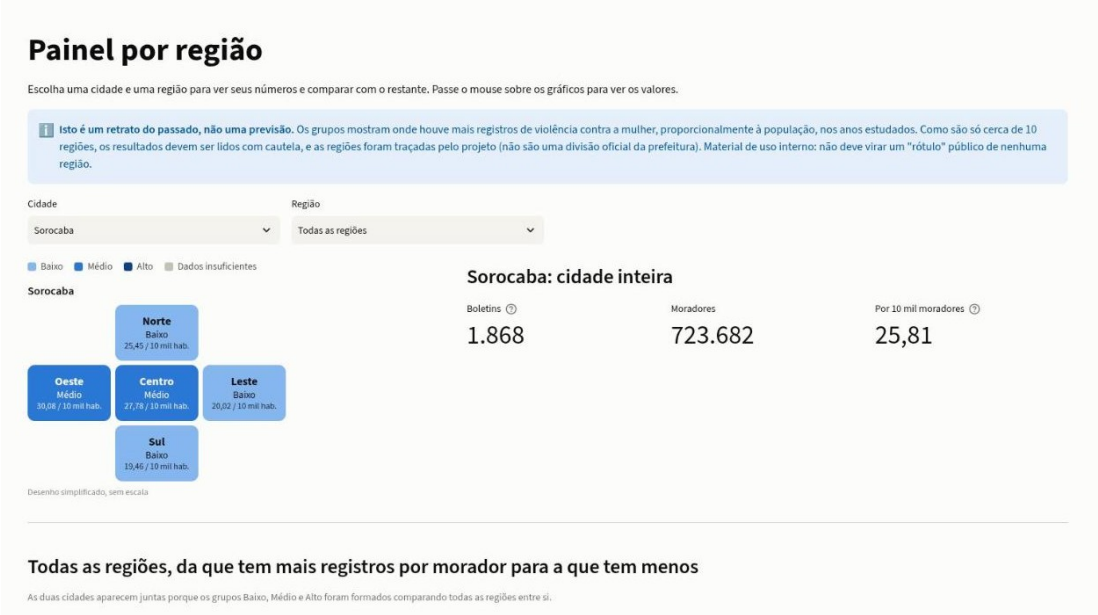
Tabela 14 – Resultado do plano de testes

Teste	Resultado obtido
Tabelas	classes_historicas_zonas com 10 zonas (9 classificadas e 1 com dados insuficientes) e o período 2023 a 2026
Coerência	Votorantim, Centro: 145 ÷ 26.142 × 10.000 = 55,47, igual à tabela
Proteção	ocorrencias_ddm sem número do boletim, logradouro ou coordenadas (16 colunas, com id_bo pseudonimizado)
Acesso	Usuário do workspace sem permissão teve o acesso ao catálogo pi6 negado
Modelo	XGBoost registrado, com os marcadores de seleção e o p-valor no MLflow
Aplicativo	Em 17/10/2026, as quatro páginas abriram com o login do workspace e mostraram os mesmos valores das tabelas (por exemplo, 2.392 registros com zona e 9 de 10 zonas comparadas)
Permissões do aplicativo	Identidade de serviço com SELECT só nas tabelas agregadas; nenhuma permissão em ocorrencias_ddm nem no esquema restrito

Fonte: Elaborado pelas autoras (2026).

A Figura 7 mostra a página Painel por região do aplicativo, com Sorocaba selecionada: o esquema das zonas por classe e os totais da cidade, sempre agregados.

Figura 7 – Página Painel por região do aplicativo pi6-zonas



Fonte: Elaborado pelas autoras (2026), com captura de tela do aplicativo.

Durante o desenvolvimento, as seguintes falhas foram encontradas e corrigidas:

a) o armazenamento público de arquivos do Databricks (DBFS) estava desabilitado; os arquivos baixados passaram a ser gravados temporariamente no disco do cluster;

b) a API Overpass recusava as consultas (erro 406) e, em outro momento, ficou sobrecarregada (erro 504); a consulta passou a usar um identificador próprio, novas tentativas com espera crescente e servidores alternativos, e o notebook passou a parar com mensagem clara se faltarem os bairros de algum município;

c) o site da Fundação SEADE não responde a partir do Databricks; o repositório passou a guardar um extrato do IPVS com as colunas usadas, gerado do arquivo oficial;

d) a tabela usada nas métricas da versão anterior deste relatório vinha da execução por bairro, e não da execução por zona; todos os números foram refeitos a partir da execução por zona;

e) o modelo registrado era sempre o XGBoost; passou a ser o de maior F1-score;

f) a correspondência por nome parecido ligava 37% dos bairros ao bairro errado; foi feita a verificação manual descrita na seção 3.5;

g) a zona Centro de Votorantim não continha o centro real da cidade; a referência foi corrigida (seção 3.4);

h) a coluna de ano misturava o ano de registro com o mês do fato; as duas datas foram separadas (seção 3.1);

i) o classificador de referência com sorteio único se repetia em todas as rodadas do leave-one-out; passou a ser a média de 200 sorteios.

4.6 Limitações

a) subnotificação: os dados refletem só os casos registrados nas DDMs, e as taxas devem ser lidas como taxas de registro, não de ocorrência real (VASCONCELOS *et al.*, 2024);

b) poucas unidades: são nove zonas classificáveis, o que torna os tercis sensíveis a cada zona e não sustenta um classificador;

c) zonas calculadas: as zonas não são uma divisão oficial, e o raio de 1.500 m foi escolhido, não calculado; a sensibilidade dos resultados ao raio não foi testada;

d) pontos diferentes para registros e população: a zona dos registros vem do ponto do bairro, e a da população vem do centro de cada setor censitário; um bairro grande pode ter setores em mais de uma zona;

e) diferença temporal: registros de 2023 a 2026 são divididos pela população de 2022, o único Censo disponível;

f) registros sem zona: 121 registros (4,8%) ficaram sem zona, 49 deles sem bairro informado;

g) dados do OpenStreetMap: a lista de bairros pode mudar entre extrações, e alguns bairros dos boletins não existem no mapa;

h) reprodutibilidade da fonte: o pipeline baixa a versão atual das planilhas da SSP-SP, sem guardar uma cópia da planilha original; a base de 08/10/2026 pode ser recuperada pelo histórico do Delta Lake enquanto ele for mantido.

5 CONCLUSÃO

O PI6 desenvolveu, no Databricks, um pipeline reproduzível que integra dados públicos da SSP-SP, do Censo 2022, do IPVS e do OpenStreetMap para analisar os registros de violência contra a mulher em Sorocaba e Votorantim por zona, e um aplicativo que disponibiliza os resultados agregados com acesso controlado. Em relação aos objetivos específicos:

a) a caracterização histórica foi realizada: 2.513 registros entre 2023 e agosto de 2026, concentrados em residências (84,0%) e em lesão corporal dolosa, com 6,4% de registros feitos em ano posterior ao do fato;

b) a integração das fontes foi realizada, e a verificação manual da correspondência de bairros reduziu os registros sem zona de 16,4% para 4,8%;

c) a análise descritiva mostrou associações fracas ou moderadas, sem significância estatística com nove zonas, entre os indicadores socioeconômicos, inclusive a vulnerabilidade social do IPVS, e a taxa;

d) a aplicação do aprendizado de máquina foi avaliada com validação leave-one-out e teste de permutação, e mostrou que, com nove zonas, os classificadores não superam o acaso, sem e com a variável do IPVS ($p = 0,68$ e, na execução final, $p = 0,66$);

e) a adequação à LGPD foi realizada com minimização de campos, pseudonimização do número do boletim, agregação por zona, orientação jurídica, plano de descarte e acesso do aplicativo restrito a tabelas agregadas.

O resultado principal é a classificação histórica normalizada pela população. Ela mostrou que, embora Sorocaba concentre o maior número de registros, as maiores taxas estão em Votorantim, com destaque para a zona Centro (55,47 registros por 10.000 habitantes). Essa classificação deve ser usada como apoio interno à análise territorial, e não como rótulo público, previsão ou medida de perigo dos territórios.

Como continuidade, recomenda-se: apresentar os resultados à DDM e registrar a sua avaliação; formalizar o termo de compromisso de não divulgação dos dados brutos, conforme a orientação jurídica; aumentar o número de unidades de análise, incluindo outros municípios ou analisando zona e ano em conjunto; testar a

sensibilidade dos resultados ao raio da zona Centro; guardar uma cópia das planilhas originais a cada extração; e manter a verificação manual sempre que o OpenStreetMap ou os nomes de bairro mudarem. Mais variáveis não resolveriam a limitação: com nove zonas, acrescentar variáveis aumenta a chance de o modelo encontrar combinações que separam as zonas da base só por coincidência, como ocorreu na execução com 15 variáveis (Tabela 12). O caminho é aumentar o número de unidades de análise.

REFERÊNCIAS

ARMBRUST, Michael *et al*. Delta Lake: high-performance ACID table storage over cloud object stores. **Proceedings of the VLDB Endowment**, v. 13, n. 12, p. 3411-3424, 2020.

ARMBRUST, Michael; GHODSI, Ali; XIN, Reynold; ZAHARIA, Matei. Lakehouse: a new generation of open platforms that unify data warehousing and advanced analytics. *In*: CONFERENCE ON INNOVATIVE DATA SYSTEMS RESEARCH, 11., 2021, [*on-line*]. **Proceedings** [...]. [*S. l.*]: CIDR, 2021.

BRASIL. Lei nº 11.340, de 7 de agosto de 2006. Cria mecanismos para coibir a violência doméstica e familiar contra a mulher [...]. **Diário Oficial da União**: seção 1, Brasília, DF, 8 ago. 2006.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). **Diário Oficial da União**: seção 1, Brasília, DF, 15 ago. 2018.

BRASIL. Ministério da Saúde. **Indicadores básicos para a saúde no Brasil**: conceitos e aplicações. 2. ed. Brasília, DF: Organização Pan-Americana da Saúde, 2008. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/indicadores_basicos_saude_brasil_2ed.pdf. Acesso em: 8 out. 2026.

BREIMAN, Leo. Random forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001.

BREIMAN, Leo; FRIEDMAN, Jerome H.; OLSHEN, Richard A.; STONE, Charles J. **Classification and regression trees**. Belmont: Wadsworth, 1984.

CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: a scalable tree boosting system. *In*: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016, San Francisco. **Proceedings** [...]. New York: ACM, 2016. p. 785-794.

DATABRICKS. **Databricks documentation**. [*S. l.*], 2026. Disponível em: https://docs.databricks.com/. Acesso em: 8 out. 2026.

GOOGLE. **Google Maps**. [*S. l.*], 2026. Disponível em: https://www.google.com/maps. Acesso em: 8 out. 2026.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **Censo Demográfico 2022**: agregados por setores censitários. Rio de Janeiro: IBGE, [2026]. Disponível em: https://ftp.ibge.gov.br/Censos/Censo_Demografico_2022/Agregados_por_Setores_Censitarios/. Acesso em: 8 out. 2026.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **Malha de setores censitários**: Censo Demográfico 2022. Rio de Janeiro: IBGE, [2022]. Disponível em: https://geoftp.ibge.gov.br/organizacao_do_territorio/malhas_territoriais/malhas_de_setores_censitarios__divisoes_intramunicipais/censo_2022/setores/shp/UF/. Acesso em: 8 out. 2026.

JAMES, Gareth; WITTEN, Daniela; HASTIE, Trevor; TIBSHIRANI, Robert. **An introduction to statistical learning**: with applications in R. 2. ed. New York: Springer, 2021.

KAUFMAN, Shachar; ROSSET, Saharon; PERLICH, Claudia; STITELMAN, Ori. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, p. 1-21, 2012.

KRAWCZYK, Hugo; BELLARE, Mihir; CANETTI, Ran. **HMAC**: keyed-hashing for message authentication. RFC 2104. [*S. l.*]: Internet Engineering Task Force, 1997. Disponível em: https://www.rfc-editor.org/rfc/rfc2104. Acesso em: 8 out. 2026.

LIMA, Geovanna Carvalho Cardoso; PASSOS, Camila Mendes dos; PINHEIRO, Alba Lúcia Santos; RIBEIRO, Ícaro José Santos; MAIA, Emanuella Gomes. Tendência temporal e perfil epidemiológico das notificações de violência contra as mulheres no Brasil: 2014-2023. **Epidemiologia e Serviços de Saúde**, Brasília, v. 34, e20240475, 2025. DOI: 10.1590/S2237-96222025v34e20240475.pt.

MLFLOW. **MLflow documentation**. [*S. l.*], 2026. Disponível em: https://mlflow.org/docs/latest/. Acesso em: 8 out. 2026.

NOMINATIM. **Nominatim**: open-source geocoding with OpenStreetMap data. [*S. l.*], 2026. Disponível em: https://nominatim.org/. Acesso em: 8 out. 2026.

OJALA, Markus; GARRIGA, Gemma C. Permutation tests for studying classifier performance. **Journal of Machine Learning Research**, v. 11, p. 1833-1863, 2010.

OPENSHAW, Stan. **The modifiable areal unit problem**. Norwich: Geo Books, 1984. (Concepts and Techniques in Modern Geography, 38).

OPENSTREETMAP CONTRIBUTORS. **OpenStreetMap**. [*S. l.*], 2026. Disponível em: https://www.openstreetmap.org. Acesso em: 8 out. 2026.

ORGANIZAÇÃO PAN-AMERICANA DA SAÚDE (OPAS). **Violência contra as mulheres**. Washington, DC: OPAS, [2025]. Disponível em: https://www.paho.org/pt/topics/violence-against-women. Acesso em: 8 out. 2026.

OVERPASS API. **Overpass API**: interface de consulta aos dados do OpenStreetMap. [*S. l.*], 2026. Disponível em: https://overpass-api.de/api/interpreter. Acesso em: 8 out. 2026.

PEDREGOSA, Fabian *et al*. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

SÃO PAULO (Estado). Secretaria da Segurança Pública. **Estatística**: consultas. São Paulo: SSP, [2025]. Disponível em: https://www.ssp.sp.gov.br/estatistica/consultas. Acesso em: 8 out. 2026.

SÃO PAULO (Estado). Secretaria da Segurança Pública. **SPDados Criminais**: planilhas anuais de ocorrências registradas. São Paulo: SSP, [2026]. Disponível em: https://www.ssp.sp.gov.br/assets/estatistica/transparencia/spDados/. Acesso em: 8 out. 2026.

SEADE (Fundação Sistema Estadual de Análise de Dados). **Índice Paulista de Vulnerabilidade Social – IPVS versão 2022**: bases cartográficas. São Paulo: Seade, 2025. Disponível em: https://repositorio.seade.gov.br/dataset/seade-ipvs. Acesso em: 8 out. 2026.

SEADE (Fundação Sistema Estadual de Análise de Dados). **IPVS versão 2022**: metodologia. São Paulo: Seade, 2026. Disponível em: https://repositorio.seade.gov.br/dataset/ipvs-anexo-metodologico. Acesso em: 8 out. 2026.

SOKOLOVA, Marina; LAPALME, Guy. A systematic analysis of performance measures for classification tasks. **Information Processing & Management**, v. 45, n. 4, p. 427-437, 2009.

VARMA, Sudhir; SIMON, Richard. Bias in error estimation when using cross-validation for model selection. **BMC Bioinformatics**, v. 7, art. 91, 2006. DOI: 10.1186/1471-2105-7-91.

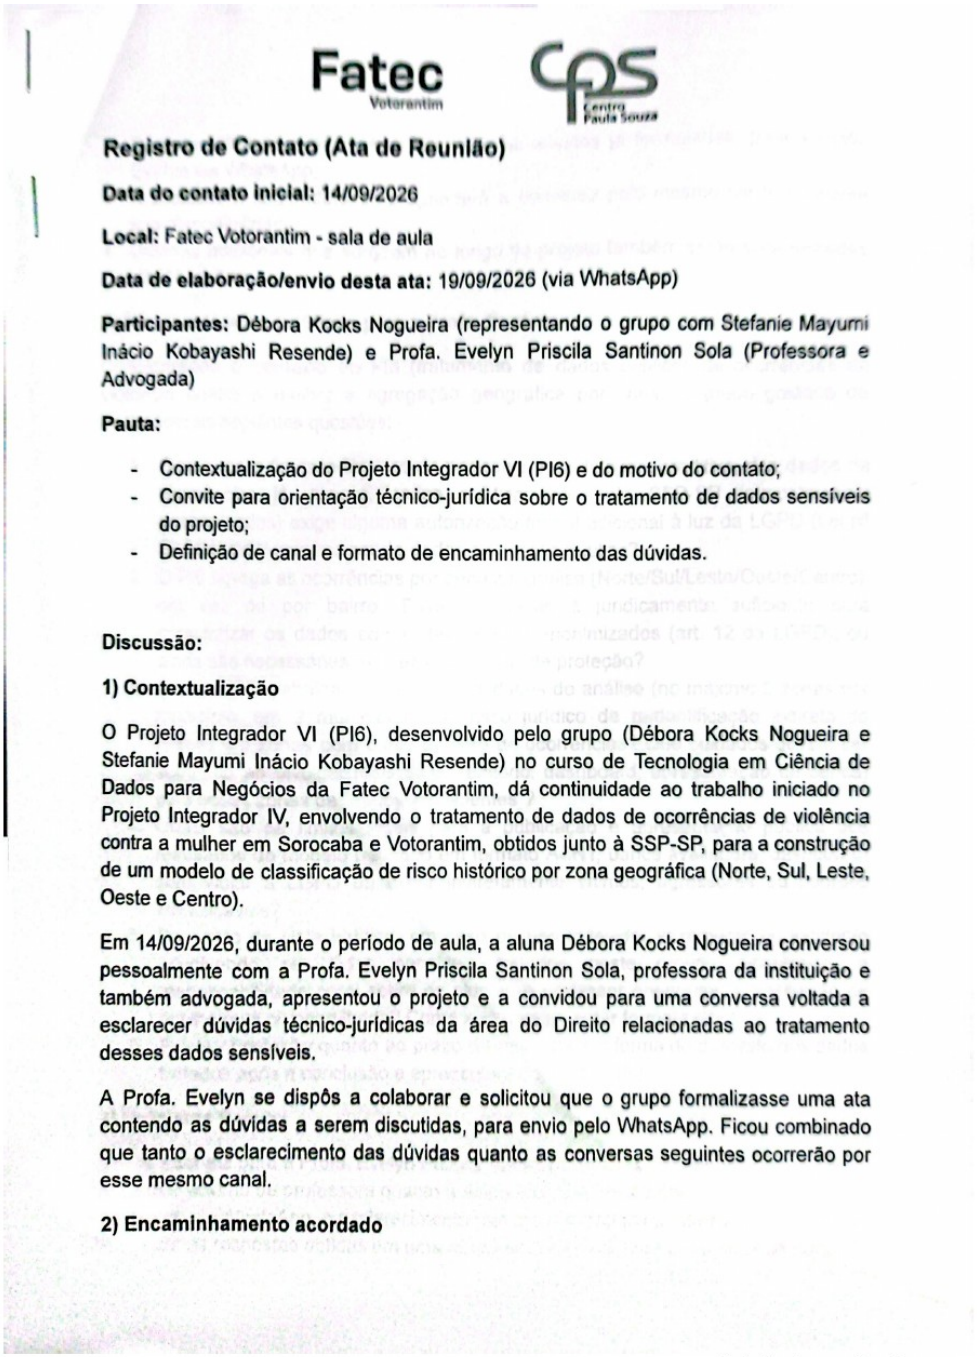
VASCONCELOS, Nádia Machado de; BERNAL, Regina Tomie Ivata; SOUZA, Juliana Bottoni de; BORDONI, Polyanna Helena Coelho; STEIN, Caroline; COLL, Carolina de Vargas Nunes; MURRAY, Joseph; MALTA, Deborah Carvalho. Subnotificação de violência contra as mulheres: uma análise de duas fontes de dados. **Ciência & Saúde Coletiva**, Rio de Janeiro, v. 29, n. 10, e07732023, 2024. DOI: 10.1590/1413-812320242910.07732023.

ZAHARIA, Matei *et al*. Accelerating the machine learning lifecycle with MLflow. **IEEE Data Engineering Bulletin**, v. 41, n. 4, p. 39-45, 2018.

APÊNDICE A – REGISTRO DE CONTATO COM A PROFA. EVELYN PRISCILA SANTINON SOLA (14/09/2026)

O registro a seguir documenta o contato do grupo com a Profa. Evelyn Priscila Santinon Sola, professora e advogada da Fatec Votorantim, em 14/09/2026, com as questões encaminhadas sobre o tratamento dos dados e as respostas recebidas, relacionadas às medidas adotadas na Tabela 13 (seção 4.4).

Registro de contato de 14/09/2026, página 1



Fatec Votorantim — CPS Centro Paula Souza

Registro de Contato (Ata de Reunião)

Data do contato inicial: 14/09/2026

Local: Fatec Votorantim - sala de aula

Data de elaboração/envio desta ata: 19/09/2026 (via WhatsApp)

Participantes: Débora Kocks Nogueira (representando o grupo com Stefanie Mayumi Inácio Kobayashi Resende) e Profa. Evelyn Priscila Santinon Sola (Professora e Advogada)

Pauta:

- Contextualização do Projeto Integrador VI (PI6) e do motivo do contato;
- Convite para orientação técnico-jurídica sobre o tratamento de dados sensíveis do projeto;
- Definição de canal e formato de encaminhamento das dúvidas.

Discussão:

1) Contextualização

O Projeto Integrador VI (PI6), desenvolvido pelo grupo (Débora Kocks Nogueira e Stefanie Mayumi Inácio Kobayashi Resende) no curso de Tecnologia em Ciência de Dados para Negócios da Fatec Votorantim, dá continuidade ao trabalho iniciado no Projeto Integrador IV, envolvendo o tratamento de dados de ocorrências de violência contra a mulher em Sorocaba e Votorantim, obtidos junto à SSP-SP, para a construção de um modelo de classificação de risco histórico por zona geográfica (Norte, Sul, Leste, Oeste e Centro).

Em 14/09/2026, durante o período de aula, a aluna Débora Kocks Nogueira conversou pessoalmente com a Profa. Evelyn Priscila Santinon Sola, professora da instituição e também advogada, apresentou o projeto e a convidou para uma conversa voltada a esclarecer dúvidas técnico-jurídicas da área do Direito relacionadas ao tratamento desses dados sensíveis.

A Profa. Evelyn se dispôs a colaborar e solicitou que o grupo formalizasse uma ata contendo as dúvidas a serem discutidas, para envio pelo WhatsApp. Ficou combinado que tanto o esclarecimento das dúvidas quanto as conversas seguintes ocorrerão por esse mesmo canal.

2) Encaminhamento acordado

Digitalizado com CamScanner

Registro de contato de 14/09/2026, página 2

Fatec Votorantim — Centro Paula Souza

- O grupo elabora e envia esta ata, com as dúvidas já formuladas, para a Profa. Evelyn via WhatsApp;
- A professora responderá e/ou agendará a conversa pelo mesmo canal, conforme sua disponibilidade;
- Dúvidas adicionais que surgirem ao longo do projeto também serão encaminhadas via WhatsApp.

3) Dúvidas técnico-jurídicas para a Profa. Evelyn

Considerando o contexto do PI6 (tratamento de dados públicos de ocorrências de violência contra a mulher e agregação geográfica por zona), o grupo gostaria de esclarecer as seguintes questões:

1. O uso, para fins acadêmicos de pesquisa e modelagem preditiva, dos dados de ocorrências já disponibilizados publicamente pela SSP-SP (supostamente anonimizados) exige alguma autorização formal adicional à luz da LGPD (Lei nº 13.709/2018), mesmo sendo dados de acesso público?
2. O PI6 agrega as ocorrências por zona geográfica (Norte/Sul/Leste/Oeste/Centro), em vez de por bairro. Essa agregação é juridicamente suficiente para caracterizar os dados como efetivamente anonimizados (art. 12 da LGPD), ou ainda são necessárias medidas adicionais de proteção?
3. Como o PI6 trabalha com poucas unidades de análise (no máximo 5 zonas por município, em 2 municípios), há risco jurídico de reidentificação indireta de vítimas em zonas com baixo número de ocorrências? Que cuidados devem ser adotados ao divulgar resultados (relatório, dashboard, apresentação de banca) para essas zonas de "dados insuficientes"?
4. Quais são os limites legais para a publicação e apresentação pública dos resultados do modelo (relatório em formato ABNT, banca avaliadora, dashboard) sem violar a LGPD ou expor indiretamente vítimas, agressores ou padrões identificáveis?
5. Do ponto de vista jurídico, em caso de uso indevido, vazamento ou incidente envolvendo os dados sensíveis tratados neste projeto acadêmico, a responsabilidade recai sobre os alunos, o professor orientador, a instituição de ensino ou é compartilhada? Como isso deveria estar formalizado?
6. Existe orientação quanto ao prazo de retenção e à forma de descarte dos dados tratados após a conclusão e apresentação final do PI6?

4) Próximos Passos

Enviar esta ata para a Profa. Evelyn Priscila Santinon Sola via WhatsApp;
Aguardar retorno da professora quanto à disponibilidade para a conversa;
Conduzir, via WhatsApp, o esclarecimento das dúvidas técnico-jurídicas listadas acima;
Registrar as respostas obtidas em uma nova ata, a ser assinada por ambas as partes.

Digitalizado com CamScanner

Registro de contato de 14/09/2026, página 3

Fatec Votorantim

Centro Paula Souza

Responsável pela ata: Débora Kocks Nogueira

Assinaturas:

Débora Kocks Nogueira - Aluna

Stefanie Mayumi Inácio Kobayashi Resende - Aluna

Profa. Evelyn Priscila Santinon Sola - Professora / Advogada

Digitalizado com CamScanner

Registro de contato de 14/09/2026, página 4

1. Não seria exigida, pois além da LGPD não ser aplicável ao tratamento da dados para fins exclusivamente acadêmicos, bases de dados públicas não dependem de consentimento. Porém, devemos observar "a finalidade, a boa-fé e o interesse público que justificaram sua disponibilização", conforme art. 7º da LGPD. Uma pesquisa acadêmica sobre violência contra a mulher é compatível com a finalidade da divulgação pela SSP-SP, que é a transparência. Esses dados, de acordo com a classificação da lei, não são considerados sensíveis.
2. Em regra, seria suficiente, já que os dados já vem anomizados de base antes de tornarem-se públicos. Anomizado para a lei seria "considerando a utilização de meios técnicos razoáveis e disponíveis" (art. 5º, III; art. 12, §1º). A base bruta no momento da entrada a qual deve ser observada, o que não é do controle do grupo. Porém, para minimizar alguns incidentes, devemos aplicar o previsto como princípio da necessidade, ou seja, todos aqueles dados que fossem desnecessários, poderão ser excluídos antes da agregação. O Grupo deverá listar as colunas da base e descartar as desnecessárias, principalmente aquelas que permitiriam em tese a reidentificação. Desta forma, poderá listar essa decisão no relatório como medida de minimização de acordo com o art. 6, III da LGPD.
3. Existiria risco principalmente em locais como zona, tipo de crime, mês e faixa. A sugestão para o grupo seria eliminar ou agrupar células com poucas ocorrências e exibir dados insuficientes, justificando no relatório o critério do grupo, apesar de não haver exigência legal, uma vez que não há na lei "número mínimo de casos".
4. A demonstração deve focar somente nos dados agregados e não em registros individuais. Deve ser aplicada minimização, conforme princípio da necessidade. O grupo não deverá expor casos individuais e nem estigmatizar em seus resultados zonas como perigosas, de acordo com o art. 6º, VIII, LGPD, conhecido como princípio da prevenção. Tomar certo cuidado com o dashboard para apresentação, pois não poderá ser exposto a qualquer pessoa, para não ser cruzado com outras fontes.
5. Quem tem gestão sobre o tratamento é o controlador, segundo o art. 5º, VI da LGPD. Em um projeto de curso, a instituição costuma figurar como controladora, já que define a finalidade e os recursos. Alunos e orientador atuam como operadores. Qualquer dano deverá ser reparado de acordo com os artigos 42 e 44 da LGPD, em especial desacordos com lei ou falta de segurança na manipulação dos dados. Para evitar essas questões, recomendo a assinatura de um termo de compromisso dos alunos, com o escopo do uso e a vedação de compartilhar a base bruta. Os alunos também deverão manter um registro simples das operações (art. 37,LGPD), conforme orientado nas aulas de Direito Digital.
6. Nos projetos acadêmicos, não há nenhum prazo legal específico para descarte, porém os alunos foram orientados a fazer um plano de destruição dos dados, uma vez que o tratamento finalizaria, pela lei, de acordo com o art. 15 e 16 da LGPD, quando a finalidade for alcançada. Como no caso em questão a base é pública, não existe razão para guardar a cópia bruta após a banca, porém recomendo a consulta as posturas e indicações existentes do professor-gestor e da coordenação de curso. A sugestão é traçar um plano de distribuição do arquivo bruto ao final, bem como manter somente o código, documentando em uma ata a data do descarte e a execução do plano de destruição dos dados nas máquinas. Além disso, sugiro a aplicação de cláusula de sigilo junto aos participantes (alunos) por dois anos para as questões tratadas no trabalho.

Evelyn P. Santinon Sota

Advogada e professora da FATEC-Votorantim

Digitalizado com CamScanner